

Transformer 学习在上下文学习中实现预条件梯度下降

Kwangjun Ahn^{1,3,*}, Xiang Cheng^{1,3,*}, Hadi Daneshmand^{2,3,*}, and Suvrit Sra^{1,3}

¹Department of Electrical Engineering and Computer Science, MIT

²Foundations of Data Science Institute (FODSI)

³Laboratory for Information and Decision Systems (LIDS), MIT

2025 年 5 月 8 日

摘要

受 transformer 在上下文学习中的显著能力的启发，一些研究证明 transformer 可以实现梯度下降等算法。通过仔细构造权重，这些研究显示，多个层的 transformer 具有足够的表达能力来模拟梯度下降的迭代过程。超越了表达能力的问题，我们提出：*transformer* 能否通过在随机问题实例上的训练来学习实现此类算法？据我们所知，我们通过分析线性 transformer 在随机线性回归实例上的损失景观，首次在理论上取得了进展。对于单个注意力层，我们证明训练目标的全局最小值实现了预处理梯度下降的一次迭代。值得注意的是，预处理矩阵不仅适应于输入分布，还适应于数据不足引起的方差。对于具有 k 个注意力层的 transformer，我们证明训练目标的某些临界点实现了 k 次预处理梯度下降的迭代。我们的结果呼吁未来对通过训练 transformer 学习算法进行理论研究。

1 引言

在上下文学习 (ICL) 中，大型语言模型表现出惊人的适应输入结构的能力：给定包含示例和查询的提示，Transformer 会根据示例提供的上下文生成正确的输出，而无需更新其参数 [Brown et al., 2020, Lieber et al., 2021, Rae et al., 2021, Black et al., 2022]。这一特性已成为近期研究关注的焦点，这些研究旨在揭示大型语言模型的潜在机制 [Garg et al., 2022, Akyürek et al., 2022, von Oswald et al., 2022, Li and Malik, 2017, Min et al., 2021, Xie et al., 2021, Elhage et al., 2021, Olsson et al., 2022]。

一种研究方向通过 Transformer 的表达能力来研究 ICL。Transformer 架构是强大的图灵机，能够实现各种算法 [Pérez et al., 2021, Wei et al., 2022]。给定一个上下文提示，Edelman et al. [2022], Olsson et al. [2022] 认为 Transformer 能够通过多头注意力的循环来实现算法，从原始输入提示中

* 同等贡献，按字母顺序排列。

提取粗粒度信息。Akyürek et al. [2022], von Oswald et al. [2022] 断言 Transformer 可以在给定输入提示中编码的线性回归上实现梯度下降。

虽然 Transformer 是实现算法的通用机器，但它们需要特定的参数配置来实现这些功能。在实际中，它们的参数是通过在随机问题实例上使用非凸优化进行训练来调整的。因此，尚不清楚优化这种非凸目标是否会教会 Transformer 实现有意义的算法。本文研究了神经网络实现算法的能力，不是通过将权重设置为精心设计的值，而是通过在随机问题实例上简单地进行训练。更具体地说，我们研究了 Transformer 如何学习实现基于梯度的方法。

实证证据表明，经过在随机线性回归实例上的训练后，Transformer 确实学会了实现梯度下降 [Garg et al., 2022, Akyürek et al., 2022, von Oswald et al., 2022]。这种学习梯度下降的倾向令人惊讶，因为 Transformer 是过度参数化的，因此其表达能力足够强，可以实现各种复杂的优化方法，这些方法可能同样有效。受这一观察的启发，我们从理论上研究了 ICL 的损失景观；我们的发现揭示了梯度下降作为被学习算法的潜在机制。与最近的工作类似，我们也专注于通过 ICL 编码的线性回归情景，对于这种情况，我们在没有 Softmax 的情况下训练了一个具有多层单头自注意力的 Transformer 架构。

主要贡献。 我们的主要贡献如下：

- 我们提供了对具有线性注意力的单层 Transformer 的唯一全局最优解的完整表征。特别是，我们观察到，当参数最优时，Transformer 实现了预条件梯度下降的一个步骤。值得注意的是，预条件矩阵不仅适应输入数据的分布，还适应由数据不足引起的方差。我们在第4节的定理1中呈现了这一结果。
- 接下来，我们关注由特殊稀疏性条件 (5) 定义的 Transformer 参数空间的一个子集。这种参数配置使我们能够将训练 Transformer 问题表述为对 k -步自适应基于梯度的算法的搜索。定理3描述了在各向同性回归实例上，两层线性 Transformer 训练目标的全局极小解，并表明这些最优解对应于自适应步长的梯度下降。在定理4中，我们考虑了更一般的 多层 Transformer 情景，其中协变量具有 各向异性协方差。我们证明了上下文损失的某些临界点会引发一种预处理梯度算法，其中预处理矩阵适应输入数据的分布，并类似于牛顿法等算法。
- 最后，我们研究了在没有上述稀疏性条件 (5) 的情况下损失景观；这超越了对传统基于梯度的最优化方法的搜索。我们表明，上下文中的损失的一个临界点导致了一个有趣的算法，该算法同时采用由逆数据协方差预处理的梯度步骤，并应用线性变换以迭代改善条件数。在数据协方差各向同性的特定情况下，该算法对应于 von Oswald et al. [2022] 的 GD++ 算法。

我们通过实验验证了定理4和定理5中分析的临界点。对于具有三层的 Transformer，我们的实验结果确认了临界点的结构。此外，我们观察到与这些临界点相关的目标值接近0，这表明临界点可能是全局最优的。

2 相关作品

神经网络的计算能力。 人们一直在寻找具有神经网络的学习算法。Siegelmann and Sontag [1992] 的开创性工作研究了循环神经网络的计算能力，证明了它们的图灵完备性。尽管具有这种计算能力，训练循环网络仍然是一个挑战。为了解决这个问题，Graves et al. [2014] 设计了一种称为“神经图灵机”的替代神经架构。Hochreiter and Schmidhuber [1997] 引入的注意力层是神经图灵机的关键构建块。利用注意力层，Vaswani et al. [2017] 提出了 Transformer 作为强大的神经架构，能够解决自然语言处理中的各种任务 [Devlin et al., 2019]。这种能力激发了一类研究，探讨 Transformer 的算法能力 [Pérez et al., 2021, Wei et al., 2022, Giannou et al., 2023, Akyürek et al., 2022, Olsson et al., 2022]。Transformer 与传统循环神经网络的不同之处在于它们在训练后的出色表现。在这里，我们研究了在使用 Transformer 学习算法时训练的核心作用。与上述工作相比，我们专注于理解 Transformer 如何通过问题实例上训练来实现算法。

上下文学习。 Transformer 已经展示了它们解决各种任务的能力，包括机器翻译、问答系统和文本摘要 [Radford et al., 2019]。与自然语言模型中的传统方法不同，Transformer 是以无监督的方式进行训练的，与具体任务无关。事实上，训练好的 Transformer 拥有从输入中提取信息的各种技能，这种特性被称为“上下文学习” (ICL) [Brown et al., 2020]。通过注意力层的归纳，Transformer 可以实现各种迭代算法来从输入中提取信息 [Edelman et al., 2022, Olsson et al., 2022, Giannou et al., 2023, Akyürek et al., 2022]。Transformer 可以在定义在其输入上的目标函数上实现梯度下降法 Akyürek et al. [2022], Olsson et al. [2022]。

算法视角可能有助于阐明 ICL 的几个特性，例如领域自适应和多任务学习。鉴于梯度下降可以优化各种目标，一个执行梯度下降的 Transformer 本质上对分布变化具有鲁棒性。这也解释了多任务学习，因为梯度下降可以解决各种优化问题。然而，尚不清楚 Transformer 如何学习执行梯度下降。我们分析用于学习梯度下降的训练目标，以研究 ICL 中学习算法的潜在机制。

3 问题设定

我们遵循 [von Oswald et al., 2022, Akyürek et al., 2022] 中研究的线性模型的场景。设 $X \in \mathbb{R}^{(n+1) \times d}$ 是一个矩阵，其第 i 行包含从分布 $D_{\mathcal{X}}$ 独立同分布抽取的词元 $x^{(i)} \in \mathbb{R}^d$ 。为了生成一组随机函数，首先抽取 $w_{\star} \sim \mathcal{N}(0, I_d)$ ，然后生成响应 $y = [\langle x^{(1)}, w_{\star} \rangle, \dots, \langle x^{(n)}, w_{\star} \rangle] \in \mathbb{R}^n$ 。定义

$$Z_0 = \begin{bmatrix} z^{(1)} & z^{(2)} & \dots & z^{(n)} & z^{(n+1)} \end{bmatrix} = \begin{bmatrix} x^{(1)} & x^{(2)} & \dots & x^{(n)} & x^{(n+1)} \\ y^{(1)} & y^{(2)} & \dots & y^{(n)} & 0 \end{bmatrix} \in \mathbb{R}^{(d+1) \times (n+1)}, \quad (1)$$

其中是一个输入矩阵，提供给神经网络以预测 $w_{\star}^{\top} x^{(n+1)}$ 。请注意上面矩阵中的零用于代替对应于 $x^{(n+1)}$ 的未知响应变量。现在让我们介绍定义和研究 ICL 所需的关键概念（如下部分 A–D）。

A. 自注意力函数。 大型语言模型中最基本的组件之一是注意力 [Vaswani et al., 2017]。注意力使网络能够利用输入的高阶矩。设 $Z \in \mathbb{R}^{d \times n}$ 包含 n 个词元在 $\mathbb{R}^d$ 中。一个单头注意力表示为

$\text{Attn}' : \mathbb{R}^{d \times n} \rightarrow \mathbb{R}^{d \times n}$ 是一个参数化函数，定义为

$$\text{Attn}'(Z) = PZM\text{softmax}(Z^\top W_k^\top W_q Z), \quad M := \begin{bmatrix} I_n & 0 \\ 0 & 0 \end{bmatrix} \in \mathbb{R}^{(n+1) \times (n+1)}, \quad (2)$$

其中 $P, W_k, W_q \in \mathbb{R}^{(d+1) \times (d+1)}$ 是 (值、键和查询) 权重矩阵，而 $\text{softmax}(\cdot)$ 是 soft-max 运算符，它对输入矩阵的每一列应用 softmax 操作，并输出一个具有非负条目的矩阵，每列的和等于 1。值得注意的是，提示是不对称的，因为 $x^{(n+1)}$ 的标签被排除在输入之外。为了处理这种不对称结构，在注意力中使用了掩码 M 。

B. 线性自注意力。 遵循 [Schlag et al., 2021, von Oswald et al., 2022]，我们考虑省略定义 (3) 中的 softmax 运算符的自注意力层。此外，我们将权重 $Q := W_k^\top W_q \in \mathbb{R}^{(d+1) \times (d+1)}$ 重新参数化为

$$\text{Attn}_{P,Q}(Z) = PZM(Z^\top QZ). \quad (3)$$

乍一看，上述注意力似乎过于简化。但我们认为，具有上述注意力的深度 Transformer 可以实现各种线性回归的最优化方法。

C. 上下文推理的架构。 为了预测 $w_\star^\top x^{(n+1)}$ ，输入矩阵 Z_0 被提供给一个带有注意力机制的 Transformer 架构。具体来说，我们考虑带有残差连接的注意力机制的重复。令 Z_ℓ 表示输入矩阵在层 ℓ 的隐藏表示，该表示遵循以下跨层的更新方程

$$Z_{\ell+1} = Z_\ell + \frac{1}{n} \text{Attn}_{P_\ell, Q_\ell}(Z_\ell). \quad (4)$$

上述 Transformer 的参数可以在各种训练输入实例上进行优化，以实现上下文学习。缩放因子 $\frac{1}{n}$ 仅用于简化表示，并不影响 Transformer 的表达能力。

D. 上下文损失。 对于层数 k ，我们使用 Z_k 来预测与 $x^{(n+1)}$ 相关的响应。这相当于使用矩阵 Z_k 的左下角，即 $[Z_k]_{(d+1), (n+1)}$ ，来预测 $w_\star^\top x^{(n+1)}$ 。特别是，由于我们在引理 2 中将要澄清的技术原因，我们将使用负数项，即 $-[Z_k]_{(d+1), (n+1)}$ 来预测 $w_\star^\top x^{(n+1)}$ 。因此，上下文损失变为（回忆层更新规则 (3)）

$$f(\{P_i, Q_i\}_{i=0}^k) = \mathbf{E}_{(Z_0, w_\star)} \left[\left([Z_k]_{(d+1), (n+1)} + w_\star^\top x^{(n+1)} \right)^2 \right], \quad (5)$$

其中 $[X]_{i,j}$ 表示矩阵 X 的 (i, j) -th 项。

这里，我们感兴趣的是了解 f 的最优化如何导致上下文学习，我们通过分析 f 的地形来研究这个问题。然而， f 的地形分析具有挑战性，特别是由于两个主要原因：

(i) f 在参数 $\{P_i, Q_i\}$ 上是非凸的，即使对于单层 Transformer 也是如此。

(ii) 注意力中的交叉乘积结构使 f 成为参数的高非线性函数。

因此，我们分析了从单层 Transformer 到多层 Transformer 的各种情景。对于更简单的情景，如单层 Transformer，我们证明了更强的结果，例如全局极小解的完全表征。对于具有更多层的网络，我们表征了临界点的结构。此外，我们提供了对临界点的算法解释。

作为热身，我们首先从单层情况开始，即当 $k = 1$ 的情况。

4 单层 Transformer 的全局最优解

对于单层情况，我们省略下标，直接写成 $P := P_0$ 和 $Q := Q_0$ ，并重写上下文损失 (3) 作为

$$f(P, Q) = \mathbf{E}_{Z_0, w_\star} \left[\left[Z_0 + \frac{1}{n} \text{Attn}_{P, Q}(Z_0) \right]_{(d+1), (n+1)} + w_\star^\top x^{(n+1)} \right]. \quad (6)$$

仔细检查可以发现，这个目标仅依赖于 P 的最后一行和 Q 的前 n 列。换句话说， P 的前 n 行和 Q 的最后一列中的内容不会影响上下文损失。详见附录 A.1。因此，考虑以下参数化

$$P = \begin{bmatrix} 0 \\ b^\top \end{bmatrix} \quad \text{and} \quad Q = \begin{bmatrix} A & 0 \end{bmatrix}, \quad \text{where } b \in \mathbb{R}^{d+1} \text{ and } A \in \mathbb{R}^{(d+1) \times d}. \quad (7)$$

现在通过这种参数化，上下文损失可以表示为

$$f(b, A) = f \left(\begin{bmatrix} 0 \\ b^\top \end{bmatrix}, \begin{bmatrix} A & 0 \end{bmatrix} \right).$$

以下结果表征了上下文损失的最优参数 b, A 。

Theorem 1 (非各向同性提示). 假设向量 $x^{(i)}$ 从 $\mathcal{N}(0, \Sigma)$ 中采样，即协方差为 $\Sigma = U\Lambda U^\top$ 的高斯分布，其中 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_d)$ 。此外，假设 $w_\star$ 从 $\mathcal{N}(0, I_d)$ 中采样。在参数化 (4) 下，以下选择

$$b^\top = [0 \ 0 \ \dots \ 0 \ 1], \quad A = - \begin{bmatrix} U \text{diag} \left(\left\{ \frac{1}{\frac{n+1}{n} \lambda_i + \frac{1}{n} (\sum_k \lambda_k)} \right\}_i \right) U^\top \\ 0 \end{bmatrix}. \quad (8)$$

是 $f(b, A)$ 的全局最小值；其重新缩放，即 $b \leftarrow \gamma b$ 和 $A \leftarrow \gamma^{-1} A$ ，也是全局最小值。

见附录 A 中定理 1 的证明。在高斯分布各向同性的特殊情况下，即 $\Sigma = I_d$ ，最优 A 具有如下简单形式

$$A = - \frac{1}{\left(\frac{n-1}{n} + (d+2) \frac{1}{n} \right)} \begin{bmatrix} I_d \\ 0 \end{bmatrix}.$$

在缩放的前提下，上述参数配置等价于 von Oswald et al. [2022] 用于执行一次梯度下降的参数。因此，在单层情景下，上下文中的损失确实由实现梯度下降算法的 Transformer 最小化。

更一般地，当上下文样本是非各向同性时，Transformer 学会执行一步预处理的梯度下降。(1) 中的最优 A 在优化速度和统计鲁棒性之间引入了显著的权衡：

1. 当样本数量 n 较大时， $A \approx \Sigma^{-1}$ ，即输入协方差矩阵的逆，也接近于由 $x^{(1)}, \dots, x^{(n)}$ 构成的 Gram 矩阵。通过 A 进行预处理可以在输入协方差病态时显著提高收敛速度。
2. 另一方面， $\frac{1}{n} \sum_k \lambda_k$ 项在 (1) 中起到正则化项的作用。当 n 较小时且 $x^{(i)}$ 的方差较高时，该作用变得更加显著。这种调整类似于统计学习中的结构化经验风险最小化，其中正则化强度根据观测值的大小进行适应 [Vapnik, 1999]。

我们接下来进一步探讨当层数增加时的这种算法解释。

5 具有稀疏参数的多层 Transformer

我们现在考虑多层 Transformer。我们首先从一个问题开始研究：线性 Transformer 的前向传递何时会实现梯度下降的迭代？为此，我们对线性 Transformer 的参数施加以下限制：

$$P_i = \begin{bmatrix} 0_{d \times d} & 0 \\ 0 & 1 \end{bmatrix}, \quad Q_i = \begin{bmatrix} A_i & 0 \\ 0 & 0 \end{bmatrix} \quad \text{where } A_i \in \mathbb{R}^{d \times d} \text{ are symmetric matrices.} \quad (9)$$

下一个引理证明了，一个具有参数 k 的 (5) 层 Transformer 的前向传递，等同于进行 k 步梯度下降，由 A_i 预处理。在本节的其余部分，我们将研究在式 (5) 约束下上下文损失的最佳参数。第 6 节中，我们分析了更一般参数下的最佳模型。

我们将单个提示的最小二乘损失定义为

$$R_{w_*}(w) = \frac{1}{2n} \sum_{i=1}^n (w^\top x_i - w_*^\top x_i)^2. \quad (10)$$

带有自适应预条件的梯度方法通过优化 R_{w_*} 来实现

$$w_{k+1}^{\text{gd}} = w_k^{\text{gd}} + A_k \nabla R_{w_*}(w_k^{\text{gd}}). \quad (11)$$

上述迭代方案包括各种最优化方法，包括带有 $A_k = -\gamma_k I$ 的梯度下降。在最一般的情况下，(5) 包括预条件梯度下降，其中预条件器 $-A_k$ 依赖于时间步长。下一个引理证明了参数在 (5) 中的 Transformer 与使用 $-A_1, \dots, -A_k$ 的 k 步预条件梯度方法有一一对应关系。

Lemma 2. 考虑由 k 层线性变换器参数化的 $A_0 \dots A_k$ ，如 (5) 所示。令 $z^{(1)} \dots z^{(n)}$ 。对于 $i = 0 \dots k$ ，存在一个 $w_i^{\text{gd}} \in \mathbb{R}^d$ ，使得在层 i 之后的 $y^{(n+1)}$ 的预测值由 $y_i^{(n+1)} = -\langle x^{(n+1)}, w_i^{\text{gd}} \rangle$ 给出。此外，从层 i 到层 $i+1$ ， w_i^{gd} 通过预条件梯度下降进行更新。

$$w_{i+1}^{\text{gd}} = w_i^{\text{gd}} + A_i \nabla R_{w_*}(w_i^{\text{gd}}).$$

注意，对于预条件梯度下降， A_i 是负半定的。引理 2 表明，具有 Eq. (5) 中参数结构的线性 Transformer 的上下文学习可以解释为寻找最优预条件矩阵 $A_0, \dots, A_k$ 。在接下来的章节中，我们描述最优 $\{A_i\}$ 如何与输入分布相关联。

此引理还表明单层 Transformer 的最优参数，如定理 1 所建立的，实现了预条件梯度下降的一个步骤。对于多层 Transformer， $A_k = -\gamma_k I$ 的具体选择恢复了 [von Oswald et al., 2022] 的证明，表明 Transformer 可以实现梯度下降。

5.1 预热：最优两层 Transformer

对于一个两层的 Transformer，下一个定理证明了在上下文中的最优损失可以获得具有自适应坐标步长的简单梯度下降。

Theorem 3 (Global optimality for the two-layer transformer). 考虑具有参数配置如公式 (5) 所示的两层 Transformer 的上下文损失最优化

$$\min_{A_0, A_1} f \left\{ Q_i = \begin{bmatrix} A_i & 0 \\ 0 & 0 \end{bmatrix}, P_i = \begin{bmatrix} 0_{d \times d} & 0 \\ 0 & 1 \end{bmatrix} \right\}_{i=1,2},$$

假设 $x_i \stackrel{i.i.d.}{\sim} N(0, I_d)$ 和 $w_\star \sim N(0, I_d)$; 然后, 存在对角矩阵 A_0 和 A_1 是 f 的全局极小解。

将上述结果与引理 2 结合, 可以得出结论: 带有 * 坐标自适应步长 * 的梯度下降两次迭代能够实现各向同性高斯输入的最小上下文损失。如 Adagrad [Duchi et al., 2011] 这样的自适应步长梯度下降算法在机器学习中被广泛使用。虽然 Adagrad 根据具体问题实例调整其步长, 但该算法学成的步长则根据潜在的数据分布进行调整。

5.2 多层 Transformer

我们现在转向一般 k -层 Transformer 的设置, 对于任何 $k \in \mathbb{Z}^+$ 。下一个定理证明了上下文损失的某些临界点有效地实现了特定的预处理梯度算法, 其中预处理矩阵是输入分布的协方差逆矩阵。在陈述这个结果之前, 让我们先考虑一个数据协方差矩阵不是单位矩阵的激励情景:

数据视角失真的线性回归: 假设 $\bar{w}_\star \sim \mathcal{N}(0, I)$ 以及潜在协变量为 $\bar{x}^{(1)} \dots \bar{x}^{(n+1)}$, 独立同分布地从 $\mathcal{N}(0, I)$ 中抽取。我们得到 $y^{(1)} \dots y^{(n)}$, 其中 $y^{(i)} = \langle \bar{x}^{(i)}, \bar{w}_\star \rangle$ 。然而, 我们无法观测潜在协变量 $\bar{x}^{(i)}$ 。相反, 我们观测到失真的协变量 $x^{(i)} = W \bar{x}^{(i)}$, 其中 $W \in \mathbb{R}^{d \times d}$ 是一个失真矩阵。因此, 任务包括 $(x^{(1)}, y^{(1)}) \dots (x^{(n)}, y^{(n)})$ 以及 $x^{(n+1)}$ 。目标仍然是预测 $y^{(n+1)}$ 。这种情景在实践中非常常见, 当协变量通常以任意基表示时。

假设 $\Sigma := WW^\top \succ 0$ 。我们从定义中验证, 对于 $w_\star := \Sigma^{-1/2} \bar{w}_\star$, $y^{(i)} = \langle x^{(i)}, w_\star \rangle$ 。此外, $x^{(i)} \sim \mathcal{N}(0, \Sigma)$ 且 $w_\star \sim \mathcal{N}(0, \Sigma^{-1})$ 。根据引理 2, 具有权重矩阵 $\{A_0 \dots A_k\}$ 的 Transformer 实现了相对于 $R_{w_\star}(w) = \frac{1}{2n}(w - w_\star)^\top XX^\top(w - w_\star)$ 的预条件梯度下降 (如 (5) 所示), 其中 $X = [x^{(1)} \dots x^{(n)}]$ 。在该损失下, 黑塞矩阵 $\nabla^2 R_{w_\star}(w) = \frac{1}{2n} XX^\top$ (至少在 n 较大的情况下)。对于任何固定的提示, 牛顿法对应于 $A_i \propto (XX^\top)^{-1}$, 这使得即使 Σ 非常退化, 问题也变得良好条件。正如我们将在下面定理 4 中看到的, $A_i \propto \Sigma^{-1} = \mathbf{E}[XX^\top]^{-1}$ 的选择似乎在提示的期望下是局部最优的。

在陈述定理之前, 我们引入以下简化符号: 令 $A := \{A_i\}_{i=0}^k \in \mathbb{R}^{(k+1) \times d \times d}$ 。我们用 $f(A)$ 表示 $f(\{P_i, Q_i\}_{i=0}^k)$ 的上下文损失, 如 (3) 中定义的那样, 当 Q_i 依赖于 A_i 时, 且 P_i 是一个常数矩阵, 如 (5) 中所述。

Theorem 4. 假设 $x^{(i)} \stackrel{i.i.d.}{\sim} \mathcal{N}(0, \Sigma)$ 和 $w_\star \sim \mathcal{N}(0, \Sigma^{-1})$, 对于 $i = 1 \dots n$, 以及某些 $\Sigma \succ 0$ 。考虑在上下文损失下的 k -层 Transformer 的最优化, 参数配置如公式 Eq. (5) 所给定:

$$\min_{\{A_i\}_{i=0}^k} f(\{A_i\}_{i=0}^k).$$

设 $\mathcal{S} \subset \mathbb{R}^{(k+1) \times d \times d}$ 按如下方式定义: $A \in \mathcal{S}$ 当且仅当对于所有 $i \in \{0, \dots, k\}$, 存在标量 $a_i \in \mathbb{R}$

使得 $A_i = a_i \Sigma^{-1}$ 。然后

$$\inf_{A \in \mathcal{S}} \sum_{i=0}^k \|\nabla_{A_i} f(A)\|_F^2 = 0,$$

其中 $\nabla_{A_i} f$ 表示关于 *Frobenius* 范数 $\|A_i\|_F$ 的导数。

如上文动机中所讨论的，在 $A_i = a_i \Sigma^{-1}$ 的情景下，线性 Transformer 实现了一种类似于牛顿法（以及一些其他自适应算法，如 Adagrad 的全矩阵变体）的算法；当问题病态时，这些算法可以比原始梯度下降显著更快地收敛。定理4中的所提出的参数 A_i 在 n 较大时也与定理1中的 A_i 相似。然而，与定理1不同，这里不存在与统计鲁棒性的权衡；这是因为定理4中的 w_* 具有协方差矩阵 Σ^{-1} ，而定理1具有各向同性的 w_* 。

与我们之前的结果不同，定理4仅保证满足 $\{A_i \propto \Sigma^{-1}\}_{i=0}^k$ 的变换器参数集合 $\mathcal{S}$ 本质上¹包含上下文损失的临界点。然而，在下一节中，我们通过实验表明，这种 A_i 的选择确实似乎被训练所恢复。

我们将在附录 B.2 中证明定理4。由于 Transformer 函数的复杂性，即使展示局部最优性也可能具有挑战性。我们证明了上下文中的损失可以等价地写成（大致）一个涉及每层权重的矩阵多项式。通过利用提示潜在分布中的不变性，我们构建了一个完全包含在 $\mathcal{S}$ 中的流，其目标值下降速度与梯度流一样快。由于 f 是有下界的，我们得出结论，在 $\mathcal{S}$ 中必须存在梯度任意小的点。

5.3 实验证据 for 定理4

我们在这里对定理4中的结果进行了实证验证。我们考虑线性回归的 ICL 损失。维度是 $d = 5$ ，提示中的训练样本数量是 $n = 20$ 。其中 $x^{(i)} \sim \mathcal{N}(0, \Sigma)$ 和 $w_* \sim \mathcal{N}(0, \Sigma^{-1})$ ，其中 $\Sigma = U^T D^2 U$ ，其中 U 是一个均匀随机的正交矩阵，而 D 是一个固定对角矩阵，其元素为 $(1, 1, 0.5, 0.25, 1)$ 。

我们使用 L-BFGS 对三层线性 Transformer 的 f 进行优化，其中矩阵 A_0, A_1 ，和 A_2 由独立同分布的高斯矩阵初始化。图1d展示了优化过程中5次独立运行的平均损失。我们观察到训练收敛到一个几乎0的值，表明收敛到全局最小值。收敛时的参数与定理4中引入的平稳点相匹配，并且确实表现出全局最优性。

为了量化 A_0, A_1, A_2 与 Σ^{-1} 之间的相似度（在缩放范围内），我们使用规范化的 *Frobenius* 范数距离： $\text{Dist}(M, I) := \min_{\alpha} \frac{\|M - \alpha \cdot I\|}{\|M\|_F}$ ，（等价于选择 $\alpha := \frac{1}{d} \sum_{i=1}^d M[i, i]$ ）。这实际上是 $M/\|M\|_F$ 投影到缩放单位矩阵空间中的投影距离。

我们绘制了 $\text{Dist}(A_i, I)$ ，在5次运行中取平均值，与迭代次数在图1a、1b、1c中进行对比。在每个图中，蓝色线条表示 $\text{Dist}(\Sigma^{1/2} A_i \Sigma^{1/2}, I)$ ，我们验证了最优参数正在收敛到定理4中引入的临界点，该临界点实现了预处理梯度下降。红色线条表示 $\text{Dist}(A_i, I)$ ；它保持恒定，表明训练后的 Transformer 并未实现普通的梯度下降。图2a-2c展示了训练结束时每个 $\Sigma^{1/2} A_i \Sigma^{1/2}$ 矩阵，以进一步验证学成参数如定理4所描述。

¹一个微妙的问题是，下确界可能无法达到，因此可能 $\mathcal{S}$ 包含梯度任意小的点，但不包含梯度恰好为0的点。




图 1: 用于验证一般线性变换器收敛性的图，如定理 4 所定义。图 (d) 显示损失收敛到 0。图 (a)、(b)、(c) 描述了 A_i 收敛到单位变换。更具体地说，蓝色线条表示 $\text{Dist}(\Sigma^{1/2} A_i \Sigma^{1/2}, I)$ ，它衡量的是定理 4 中引入的临界点的收敛性（对应于预条件梯度下降）。红色线条表示 $\text{Dist}(A_i, I)$ ；它保持恒定，表明训练后的变换器并未执行普通的梯度下降。




图 2: Theorem 4 的情景下的学成权重可视化。我们在训练结束时可视化每个 $\Sigma^{1/2} A_i \Sigma^{1/2}$ 矩阵。请注意，学成的权重与 Theorem 4 中讨论的驻点相匹配。

6 超越标准最优化方法的多层 Transformer

在本节中，我们研究更一般的场景

$$P_i = \begin{bmatrix} B_i & 0 \\ 0 & 1 \end{bmatrix}, \quad Q_i = \begin{bmatrix} A_i & 0 \\ 0 & 0 \end{bmatrix} \quad \text{where } A_i \in \mathbb{R}^{d \times d} \text{ are symmetric matrices.} \quad (13)$$

类似于第 5 节，我们引入以下简化符号：令 $A := \{A_i\}_{i=0}^k \in \mathbb{R}^{(k+1) \times d \times d}$ 和 $B := \{B_i\}_{i=0}^k \in \mathbb{R}^{(k+1) \times d \times d}$ 。我们使用 $f(A, B)$ 来表示当 P_i 和 Q_i 如 (6) 中所述依赖于 B_i 和 A_i 时， $f(\{P_i, Q_i\}_{i=0}^k)$ 的上下文中的损失，如 (3) 中定义的 $f(\{P_i, Q_i\}_{i=0}^k)$ 的损失。

在上一节的过参数化情景中，Transformer 可以学习超越传统预条件梯度下降的算法。下一个定理证明了学习一种新型预条件梯度方法的可能性。令 k 为固定但任意的层数。

Theorem 5. 设 Σ 表示任意半正定矩阵。假设 $x^{(i)} \stackrel{iid}{\sim} \mathcal{N}(0, \Sigma)$ 和 $w_* \sim \mathcal{N}(0, \Sigma^{-1})$ ，对于 $i = 1 \dots n$ ，以及某个 $\Sigma \succ 0$ 。考虑在上下文损失中的 k -层 Transformer 的最优化，参数配置如公式 Eq. (6)

所给出的：

$$\min_{\{A_i, B_i\}_{i=0}^k} f(A, B).$$

设 $\mathcal{S} \subset \mathbb{R}^{2 \times (k+1) \times d \times d}$ 按如下方式定义： $(A, B) \in \mathcal{S}$ 当且仅当对于所有 $i \in \{0 \dots k\}$ ，存在标量 $a_i, b_i \in \mathbb{R}$ 使得 $A_i = a_i \Sigma^{-1}$ 且 $B_i = b_i I$ 。然后

$$\inf_{(A, B) \in \mathcal{S}} \sum_{i=0}^k \|\nabla_{A_i} f(A, B)\|_F^2 + \|\nabla_{B_i} f(A, B)\|_F^2 = 0, \quad (14)$$

其中 $\nabla_{A_i} f$ 表示关于 *Frobenius* 范数 $\|A_i\|_F$ 的导数。

用文字来说， $\mathcal{S}$ 中的参数矩阵实现了以下可解释的算法： $\{A_i = a_i \Sigma^{-1}\}_{i=0}^k$ 在梯度步骤中扮演了与分布相关的预条件器的角色。同时， $B_i = b_i I$ 对协变量本身进行变换，使得每个迭代中的 Gram 矩阵具有更好的条件数。当 $\Sigma = I$ 时， $A_i \propto I, b_i \propto I$ 所实现的算法正是 von Oswald et al. [2022] 中提出的 GD++ 算法（步长除外）。

结果在 (2) 中表明，集合 $\mathcal{S}$ 本质上² 包含上下文损失 $f(A, B)$ 的临界点。在下一节中，我们提供了实证证据，表明训练后的 Transformer 参数确实收敛到 $\mathcal{S}$ 中的一点。

6.1 实验证据 for 定理 5

实验设置类似于第 5.3 节：我们考虑带有 $n = 10, d = 5$ 的线性回归，其中 $x^{(i)} \sim \mathcal{N}(0, \Sigma)$ 和 $w_* \sim \mathcal{N}(0, \Sigma^{-1})$ ，其中 $\Sigma = U^T D^2 U$ ，其中 U 是一个均匀随机的正交矩阵，而 D 是一个固定对角矩阵，其条目为 $(1, 1, 0.5, 0.25, 1)$ 。我们训练一个三层线性变换器。与第 5.3 节不同，我们在 (6) 中施加约束，这比 (5) 更宽松，并且非常接近具有完整容量的线性变换器。我们使用 L-BFGS 来优化矩阵 A_0, A_1, A_2, B_0, B_1 ³。我们使用适当缩放的独立同分布高斯矩阵来初始化这些参数。我们使用不同的随机种子重复此实验 5 次，每次我们采样一个不同的 Σ 。

在图 (3c) 中，我们绘制了 L-BFGS 迭代过程中的上下文损失；损失似乎正在收敛到 0，表明参数正在收敛到全局最小值。

我们接下来验证收敛时的参数与定理 5 一致。我们将再次使用 $\text{Dist}(M, I)$ 来测量 M 到单位矩阵的距离，考虑缩放（参见章节 5.3 中 Dist 的定义）。图 3a 和 3b 显示 B_0 和 B_1 接近单位矩阵，因为 $\text{Dist}(B_i, I)$ 看起来正在减少到 0。图 3d、3e 和 3f 绘制了 $\text{Dist}(A_i, I)$ （红色线）和 $\text{Dist}(\Sigma^{1/2} A_i \Sigma^{1/2}, I)$ （蓝色线）；这些结果表明 A_i 正在收敛到 Σ^{-1} ，考虑缩放。在图 3a 和 4b 中，我们观察到 B_0 和 B_1 也收敛到单位矩阵，没有左乘和右乘 $\Sigma^{1/2}$ ，这与定理 5 一致。

我们在训练结束时的图 4a-4e 中可视化了每个 B_0, B_1, A_0, A_1, A_2 。我们突出了两个值得注意的观察结果：

²再一次，类似于定理 4 的情况，下确界可能无法达到，因此可能存在 $\mathcal{S}$ 中的点具有任意小的梯度，但不包含具有确切 0 梯度的点。

³注意，目标函数不依赖于 B_2 。




图 3: 用于验证一般线性变换收敛性的图表，如定理 5 所定义。图 (c) 显示损失收敛到 0。图 (a)、(b) 说明 B_0, B_1 收敛到单位矩阵。图 (d)、(e)、(f) 说明 A_i 的收敛到 Σ^{-1} 。


1. 令 $X_k \in \mathbb{R}^{d \times n}$ 表示 Z_k 的前 d 行，它们是在(3)中定义的层 $k-1$ 的输出。那么对 X_k 的更新是 $X_{k+1} = X_k + B_k X_k M X_k^T A_k X_k \approx X_{k+1} = X_k (I - |a_k b_k| M X_k^T X_k)$ ，其中 M 是在(3)中定义的一个掩码。正如 von Oswald et al. [2022] 所指出的，这可能是由曲率校正所推动的。
2. 如图 4c-4e 所示，矩阵 A_0, A_1, A_2 的幅度依次增加。看起来，Transformer 使用 X_0 进行了微小的梯度步进（因为 A_0 很小），并使用 X_2 进行了大的梯度步进（因为 A_2 很大）。这在直觉上是合理的，因为 X_2 相比于 X_1 更好地条件化，这是由于 B_0, B_1 的影响。这可以与图 (2a)-(2c) 中的图表进行对比，其中类似的趋势不那么明显，因为 B_i 的值被限制为 0。

7 讨论


我们迈出了一步，以证明当在一组随机问题实例上进行训练时，Transformer 可以学习算法。具体来说，我们研究了在上下文损失中进行训练时学习基于梯度的方法的可能性，用于线性回归。对于单层 Transformer，我们证明全局最小值对应于预条件梯度下降的单次迭代。对于多层结构，我们表明某些对应于上下文损失临界点的参数可以被解释为一类自适应的基于梯度的算法。

我们下面列出一些未来研究的有趣方向：


- **多层的精细景观分析。**定理 5 证明了实现梯度方法的多层 Transformer 是训练目标的临界点。然而，我们并没有证明非凸目标的所有临界点都会导致类似的最优化方法。事实上，在附录 B 的




(a) 可视化 B_0




(b) 可视化 B_1



(c) 可视化 A_0



(d) 可视化 A_1



(e) 可视化 A_2

图 4: 可视化学成权重在定理 5 的情景下的可视化。可以看出, 权重模式与定理 5 中分析的驻点相匹配。有趣的是, 似乎 Transformer 使用 X_0 进行了微小的梯度步骤 (因为 A_0 很小), 并使用 X_2 进行了大的梯度步骤 (因为 A_2 很大)。我们认为这是由于 X_2 比 X_1 更好条件化, 这是由于 B_0, B_1 的影响。

引理 8 中，我们证明了上下文中的损失可以有多个临界点。分析所有临界点的集合，并尝试理解它们的算法解释以及量化它们的（次）最优性将是很有趣的。

- **收敛到全局最优解。**虽然定理 1 为训练目标的全局极小解提供了闭式表达，但用于训练的基于梯度的最优化方法仍可能收敛到不同的平稳点。分析梯度下降在 f 上的收敛性将有助于理解 Transformer 架构的训练机制。
- **带有 Softmax 的注意力。**我们省略注意力中的 Softmax 以简化我们的分析。对于学习线性函数的具体例子，von Oswald et al. [2022] 实验表明，使用 Softmax 训练双头注意力可以实现梯度下降。在注意力中使用 Softmax 时，训练是否仍然学习梯度下降仍然是一个开放问题。
- **领域自适应的应用。**算法视角可以潜在地解释 ICL 的各种性质。例如，如果上下文损失的最小化器实现了梯度下降——梯度下降本身对提示分布的转移具有内在鲁棒性——就可以解释对分布转移的鲁棒性。这激发了对未来研究的兴趣，即训练好的 Transformer 的算法能力。

致谢

Kwangjun Ahn 受到 ONR 资助 (N00014-20-1-2394) 和 MIT-IBM Watson 以及来自国防部秘书处的 Vannevar Bush 奖学金的支持。Kwangjun Ahn 还感谢 Kwanjeong 教育基金会的支持。Xiang Cheng 感谢 NSF CCF-2112665 (TILOS 人工智能研究所) 的支持。Suvrit Sra 感谢 NSF CAREER 奖 (1846088) 以及 NSF CCF-2112665 (TILOS 人工智能研究所) 的支持。我们感谢 NSF TRIPODS 项目 (奖项 DMS-2022448) 的支持。

Kwangjun Ahn 感谢 Ekin Akyürek 和 Johannes von Oswald 在本工作初始阶段的有益讨论。我们还感谢 Alex Gu 和 Joshua Robinson 在上下文学习方面的有益讨论。

参考文献

- Ekin Akyürek, Dale Schuurmans, Jacob Andreas, Tengyu Ma, and Denny Zhou. What learning algorithm is in-context learning? investigations with linear models. *International Conference on Learning Representations*, 2022.
- Noga Alon and Joel H Spencer. *The probabilistic method*. John Wiley & Sons, 2016.
- Sid Black, Stella Biderman, Eric Hallahan, Quentin Anthony, Leo Gao, Laurence Golding, Horace He, Connor Leahy, Kyle McDonell, Jason Phang, et al. Gpt-neox-20b: An open-source autoregressive language model. *Proceedings of BigScience – Workshop on Challenges & Perspectives in Creating Large Language Models*, 2022.
- Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *Neural Information Processing Systems*, 2020.

- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1*, 2019.
- John Duchi, Elad Hazan, and Yoram Singer. Adaptive subgradient methods for online learning and stochastic optimization. *Journal of machine learning research*, 12(7), 2011.
- Benjamin L Edelman, Surbhi Goel, Sham Kakade, and Cyril Zhang. Inductive biases and variable creation in self-attention mechanisms. In *International Conference on Machine Learning (ICML)*, 2022.
- Nelson Elhage, Neel Nanda, Catherine Olsson, Tom Henighan, Nicholas Joseph, Ben Mann, Amanda Askell, Yuntao Bai, Anna Chen, Tom Conerly, Nova DasSarma, Dawn Drain, Deep Ganguli, Zac Hatfield-Dodds, Danny Hernandez, Andy Jones, Jackson Kernion, Liane Lovitt, Kamal Ndousse, Dario Amodei, Tom Brown, Jack Clark, Jared Kaplan, Sam McCandlish, and Chris Olah. A mathematical framework for transformer circuits. *Transformer Circuits Thread*, 2021. <https://transformer-circuits.pub/2021/framework/index.html>.
- Shivam Garg, Dimitris Tsipras, Percy S Liang, and Gregory Valiant. What can transformers learn in-context? a case study of simple function classes. *Advances in Neural Information Processing Systems*, 35:30583–30598, 2022.
- Angeliki Giannou, Shashank Rajput, Jy-yong Sohn, Kangwook Lee, Jason D Lee, and Dimitris Papailiopoulos. Looped transformers as programmable computers. *arXiv preprint arXiv:2301.13196*, 2023.
- Alex Graves, Greg Wayne, and Ivo Danihelka. Neural turing machines. *arXiv preprint arXiv:1410.5401*, 2014.
- Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 1997.
- Ke Li and Jitendra Malik. Learning to optimize. In *International Conference on Learning Representations*, 2017.
- Opher Lieber, Or Sharir, Barak Lenz, and Yoav Shoham. Jurassic-1: Technical details and evaluation. *White Paper. AI21 Labs*, 2021.
- Sewon Min, Mike Lewis, Luke Zettlemoyer, and Hannaneh Hajishirzi. Metaicl: Learning to learn in context. *Proceedings of the Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 2021.

- Catherine Olsson, Nelson Elhage, Neel Nanda, Nicholas Joseph, Nova DasSarma, Tom Henighan, Ben Mann, Amanda Askell, Yuntao Bai, Anna Chen, Tom Conerly, Dawn Drain, Deep Ganguli, Zac Hatfield-Dodds, Danny Hernandez, Scott Johnston, Andy Jones, Jackson Kernion, Liane Lovitt, Kamal Ndousse, Dario Amodei, Tom Brown, Jack Clark, Jared Kaplan, Sam McCandlish, and Chris Olah. In-context learning and induction heads. *Transformer Circuits Thread*, 2022.
- Jorge Pérez, Pablo Barceló, and Javier Marinkovic. Attention is turing complete. *The Journal of Machine Learning Research*, 2021.
- Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, Ilya Sutskever, et al. Language models are unsupervised multitask learners. *OpenAI blog*, 2019.
- Jack W Rae, Sebastian Borgeaud, Trevor Cai, Katie Millican, Jordan Hoffmann, Francis Song, John Aslanides, Sarah Henderson, Roman Ring, Susannah Young, et al. Scaling language models: Methods, analysis & insights from training gopher. *arXiv preprint arXiv:2112.11446*, 2021.
- Imanol Schlag, Kazuki Irie, and Jürgen Schmidhuber. Linear transformers are secretly fast weight programmers. In *International Conference on Machine Learning*, pages 9355–9366. PMLR, 2021.
- Hava T Siegelmann and Eduardo D Sontag. On the computational power of neural nets. In *Proceedings of Workshop on Computational learning theory*, 1992.
- Vladimir Vapnik. *The nature of statistical learning theory*. Springer science & business media, 1999.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 2017.
- Johannes von Oswald, Eyvind Niklasson, Ettore Randazzo, João Sacramento, Alexander Mordvintsev, Andrey Zhmoginov, and Max Vladymyrov. Transformers learn in-context by gradient descent. *arXiv preprint arXiv:2212.07677*, 2022.
- Colin Wei, Yining Chen, and Tengyu Ma. Statistically meaningful approximation: a case study on approximating turing machines with transformers. *Advances in Neural Information Processing Systems*, 35:12071–12083, 2022.
- Sang Michael Xie, Aditi Raghunathan, Percy Liang, and Tengyu Ma. An explanation of in-context learning as implicit bayesian inference. *International Conference on Learning Representations*, 2021.

Appendix

A 单层情况的证明 (定理 1)	16
A.1 重写损失函数	16
A.2 热身: 各向同性数据的证明	16
A.3 非各向同性情况的证明	19
B 多层情况的证明	22
B.1 定理 3 的证明	22
B.2 定理 4 的证明	22
B.3 定理 5 的证明	26
B.4 置换下的等价性	36
C 辅助引理	36
C.1 重新制定上下文损失	36
C.2 Lemma 2 的证明 (与预条件梯度下降的等价性)	38

A 单层情况的证明 (定理 1)

在本节中, 我们证明了单层情况下的全局极小值的特征 (定理 1)。我们首先将损失简化为更具体的形式。

A.1 重写损失函数

回忆上下文中的损失 $f(P, Q)$, 如 (4) 中定义的:

$$f(P, Q) = \mathbf{E}_{Z_0, w_\star} \left[\left[Z_0 + \frac{1}{n} \text{Attn}_{P, Q}(Z_0) \right]_{(d+1), (n+1)} + w_\star^\top x^{(n+1)} \right]^2$$

使用符号 $Z_0 = [z^{(1)} \ z^{(2)} \ \dots \ z^{(n+1)}]$, 可以将 Z_1 重写如下:

$$\begin{aligned} Z_1 &= Z_0 + \frac{1}{n} \text{Attn}_{P, Q}(Z_0) \\ &= [z^{(1)} \ \dots \ z^{(n+1)}] + \frac{1}{n} P [z^{(1)} \ \dots \ z^{(n+1)}] M \left([z^{(1)} \ \dots \ z^{(n+1)}]^\top Q [z^{(1)} \ \dots \ z^{(n+1)}] \right). \end{aligned}$$

因此, Z_1 的最后一个词元可以表示为

$$z^{(n+1)} + \frac{1}{n} \sum_{i=1}^n P z^{(i)} (z^{(i)})^\top Q z^{(n+1)} = \begin{bmatrix} x^{(n+1)} \\ 0 \end{bmatrix} + \frac{1}{n} P \sum_{i=1}^n z^{(i)} z^{(i)\top} Q \begin{bmatrix} x^{(n+1)} \\ 0 \end{bmatrix},$$

其中需要注意的是，求和是针对 $i = 1, 2, \dots, n$ 的，这是由于掩码矩阵 M 的原因。令 $b^\top$ 为 P 的最后一行， $A \in \mathbb{R}^{d+1, d}$ 为 Q 的前 d 列，那么 $f(P, Q)$ 只依赖于 b, A ，因此，我们将 $f(P, Q)$ 写作 $f(b, A)$ 。然后， $f(b, A)$ 可以重写为

$$\begin{aligned} f(b, A) &= \mathbf{E}_{Z_0, w_\star} \left[b^\top \underbrace{\frac{1}{n} \sum_i z^{(i)} z^{(i)\top}}_{=: C} A x^{(n+1)} + w_\star^\top x^{(n+1)} \right]^2 \\ &=: \mathbf{E}_{Z_0, w_\star} \left[b^\top C A x^{(n+1)} + w_\star^\top x^{(n+1)} \right]^2 = \mathbf{E}_{Z_0, w_\star} \left[(b^\top C A + w_\star^\top) x^{(n+1)} \right]^2, \end{aligned} \quad (15)$$

其中我们使用了符号 $C := \frac{1}{n} \sum_i z^{(i)} z^{(i)\top}$ 来简化。我们现在分析这个损失函数的全局极小值。

为了清楚地说明证明思路，我们首先从各向同性数据的简单情况开始证明。

A.2 热身：各向同性数据的证明

作为热身，我们首先证明当 $x^{(i)}$ 从 $\mathcal{N}(0, I_d)$ 中采样且 $w_\star$ 从 $\mathcal{N}(0, I_d)$ 中采样时的特殊情况的结果。

Step 1: 将损失函数分解为各个部分

写出 $A = [a_1 \ a_1 \ \dots \ a_d]$ ，并利用 $\mathbf{E}[x^{(n+1)}[i]x^{(n+1)}[j]] = 0$ 对 $i \neq j$ 成立的事实，我们得到

$$f(b, A) = \sum_{j=1}^d \mathbf{E}_{Z_0, w_\star} \left[b^\top C a_j + w_\star[j] \right]^2 \mathbf{E}[x^{(n+1)}[j]^2] = \sum_{j=1}^d \mathbf{E}_{Z_0, w_\star} \left[b^\top C a_j + w_\star[j] \right]^2.$$

因此，我们首先专注于分别表征求和中每个组件的全局极小值。为此，让我们如下正式定义求和中的每个组件。

$$\begin{aligned} f_j(b, A) &:= \mathbf{E}_{Z_0, w_\star} \left[b^\top C a_j + w_\star[j] \right]^2 = \mathbf{E}_{Z_0, w_\star} \left[\text{Tr}(C a_j b^\top) + w_\star[j] \right]^2 \\ &= \mathbf{E}_{Z_0, w_\star} \left[\langle C, b a_j^\top \rangle + w_\star[j] \right]^2, \end{aligned}$$

其中我们使用符号 $\langle X, Y \rangle := \text{Tr}(XY^\top)$ 表示两个矩阵 X 和 Y ，在此处及以下各处。

Step 2: 每个组件的全局极小值的特征

为了表征每个目标的全局极小值，我们证明以下结果。

Lemma 6. 假设 $x^{(i)}$ 从 $\mathcal{N}(0, I_d)$ 中采样，且 $w_\star$ 从 $\mathcal{N}(0, I_d)$ 中采样。考虑以下目标 ($\langle X, Y \rangle := \text{Tr}(XY^\top)$ 对两个矩阵 X 和 Y)

$$f_j(X) = \mathbf{E}_{Z_0, w_\star} [\langle C, X \rangle + w_\star[j]]^2.$$

然后给出一个全局最小值为

$$X_j = -\frac{1}{\left(\frac{n-1}{n} + (d+2)\frac{1}{n}\right)} E_{d+1, j},$$

其中 E_{i_1, i_2} 是一个矩阵，其第 (i_1, i_2) 个元素是 1，其他元素均为零。

Proof of Lemma 6. 首先注意 f_j 在 X 上是凸的。因此，为了证明矩阵 X_0 是 f_j 的全局最优解，只需证明在该点梯度为零，换句话说，

$$\nabla f_j(X_0) = 0.$$

为了验证这一点，让我们计算 f_j 的梯度：

$$\nabla f_j(X_0) = 2\mathbf{E}[\langle C, X_0 \rangle C] + 2\mathbf{E}[w_\star[j]C],$$

其中我们回忆到 C 被定义为

$$C = \frac{1}{n} \sum_i \begin{bmatrix} x^{(i)} x^{(i)\top} & y^{(i)} x^{(i)} \\ y^{(i)} x^{(i)\top} & y^{(i)2} \end{bmatrix}.$$

为了验证梯度等于零，让我们首先计算 $\mathbf{E}[w_\star[j]C]$ 。对于每个 $i = 1, \dots, n$ ，注意到 $\mathbf{E}[w_\star[j]x^{(i)}x^{(i)\top}] = 0$ 因为 $\mathbf{E}[w_\star] = 0$ 。此外， $\mathbf{E}[w_\star[j]y^{(i)2}] = 0$ 因为 $w_\star$ 是对称的，即 $w_\star \stackrel{d}{=} -w_\star$ ，并且 $y^{(i)} = \langle w_\star, x^{(i)} \rangle$ 。最后，对于 $k = 1, 2, \dots, d$ ，我们有

$$\mathbf{E}[w_\star[j]y^{(i)}x^{(i)}[k]] = \mathbf{E}[w_\star[j]\langle w_\star, x^{(i)} \rangle x^{(i)}[k]] = \mathbf{E}[w_\star[j]^2 x^{(i)}[j]x^{(i)}[k]] = \mathbb{1}_{[j=k]} \quad (16)$$

因为 $\mathbf{E}[w_\star[i]w_\star[j]] = 0$ 对于 $i \neq j$ 。结合上述计算，可以得出

$$\mathbf{E}[w_\star[j]C] = E_{d+1,j} + E_{j,d+1}. \quad (17)$$

我们现在计算 $\mathbf{E}[\langle C, E_{d+1,j} \rangle C]$ 。首先注意

$$\langle C, E_{d+1,j} \rangle = \sum_i \langle w_\star, x^{(i)} \rangle x^{(i)}[j].$$

因此，有

$$\mathbf{E} \left[\langle C, E_{d+1,j} \rangle \left(\sum_i x^{(i)} x^{(i)\top} \right) \right] = \mathbf{E} \left[\left(\sum_i \langle w_\star, x^{(i)} \rangle x^{(i)}[j] \right) \left(\sum_i x^{(i)} x^{(i)\top} \right) \right] = 0.$$

因为 $\mathbf{E}[w_\star] = 0$ 。接下来，我们有

$$\mathbf{E} \left[\langle C, E_{d+1,j} \rangle \left(\sum_i y^{(i)2} \right) \right] = \mathbf{E} \left[\left(\sum_i \langle w_\star, x^{(i)} \rangle x^{(i)}[j] \right) \left(\sum_i y^{(i)2} \right) \right] = 0$$

因为 $w_\star \stackrel{d}{=} -w_\star$ 。最后，我们计算

$$\mathbf{E} \left[\langle C, E_{d+1,j} \rangle \left(\sum_i y^{(i)} x^{(i)\top} \right) \right].$$

为此，注意对于 $j \neq j'$ ，

$$\mathbf{E} \left[\langle w_\star, x^{(i)} \rangle x^{(i)}[j] \langle w_\star, x^{(i')} \rangle x^{(i')}[j'] \right] = \begin{cases} \mathbf{E}[\langle x^{(i)}, x^{(i')} \rangle x^{(i)}[j]x^{(i')}[j']] = 0 & \text{if } i \neq i', \\ \mathbf{E}[\|x^{(i)}\|^2 x^{(i)}[j]x^{(i)}[j']] = 0 & \text{if } i = i', \end{cases}$$

和

$$\mathbf{E} \left[\left\langle w_*, x^{(i)} \right\rangle x^{(i)}[j] \left\langle w_*, x^{(i')} \right\rangle x^{(i')}[j] \right] = \begin{cases} \mathbf{E}[x^{(i)}[j]^2 x^{(i')}[j]^2] = 1 & \text{if } i \neq i', \\ \mathbf{E} \left[\left\langle w_*, x^{(i)} \right\rangle^2 x^{(i)}[j]^2 \right] = d + 2 & \text{if } i = i', \end{cases} \quad (18)$$

其中最后一情况来自于高斯分布的四阶矩为 3 且

$$\mathbf{E} \left[\left\langle w_*, x^{(i)} \right\rangle^2 x^{(i)}[j]^2 \right] = \mathbf{E} \left[\left\| x^{(i)} \right\|^2 x^{(i)}[j]^2 \right] = 3 + d - 1 = d + 2.$$

将上述计算结果结合起来, 我们得到

$$\begin{aligned} \mathbf{E} [\langle C, E_{d+1,j} \rangle C] &= \frac{1}{n^2} \cdot (n(n-1) + (d+2)n) (E_{d+1,j} + E_{j,d+1}) \\ &= \left(\frac{n-1}{n} + (d+2)\frac{1}{n} \right) (E_{d+1,j} + E_{j,d+1}). \end{aligned} \quad (19)$$

因此, 结合 (A.2) 和 (A.2), 结果成立。 $\square$

Step 3: 各分量的全局极小值的结合

现在我们完成了证明。由引理 6 可知

$$X_j = -\frac{1}{\left(\frac{n-1}{n} + (d+2)\frac{1}{n}\right)} E_{d+1,j},$$

是 f_j 的唯一全局最小值。因此, 若 b 和 $A = [a_1 \ a_1 \ \cdots \ a_d]$ 满足条件, 则它们达到 $f(b, A) = \sum_{j=1}^d f_j(b, A_j)$ 的全局最小值。

$$ba_j^\top = -\frac{1}{\left(\frac{n-1}{n} + (d+2)\frac{1}{n}\right)} E_{d+1,j} \quad \text{for all } i = 1, 2, \dots, d.$$

这可以通过以下选择实现:

$$b^\top = \mathbf{e}_{d+1}, \quad a_j = -\frac{1}{\left(\frac{n-1}{n} + (d+2)\frac{1}{n}\right)} \mathbf{e}_j \quad \text{for } i = 1, 2, \dots, d,$$

其中 $\mathbf{e}_j$ 是 j -th 坐标向量。这种选择精确对应于

$$b = \mathbf{e}_{d+1}, \quad A = -\frac{1}{\left(\frac{n-1}{n} + (d+2)\frac{1}{n}\right)} \begin{bmatrix} I_d \\ 0 \end{bmatrix}.$$

接下来我们转向各向异性的情况。

A.3 非各向同性情况的证明

Step 1: 对角协方差情形

我们首先考虑 $x^{(i)}$ 从 $\mathcal{N}(0, \Lambda)$ 中采样的情形, 其中 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_d)$ 和 w_* 从 $\mathcal{N}(0, I_d)$ 中采样。我们证明以下引理 6 的推广形式。

Lemma 7. 假设 $x^{(i)}$ 从 $\mathcal{N}(0, \Lambda)$ 中采样, 其中 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_d)$ 和 $w_\star$ 从 $\mathcal{N}(0, I_d)$ 中采样。考虑以下目标

$$f_j(X) = \mathbf{E}_{Z_0, w_\star} [\langle C, X \rangle + w_\star[j]]^2.$$

然后给出一个全局最小值为

$$X_j = -\frac{1}{\frac{n+1}{n}\lambda_j + \frac{1}{n} \cdot (\sum_k \lambda_k)} E_{d+1,j},$$

其中 E_{i_1, i_2} 是一个矩阵, 其第 (i_1, i_2) 个元素是 1, 其他元素均为零。

Proof of Lemma 7. 类似地, 证明引理 6, 只需检查

$$2\mathbf{E}[\langle C, X_0 \rangle C] + 2\mathbf{E}[w_\star[j]C] = 0,$$

其中我们回忆到 C 被定义为

$$C = \frac{1}{n} \sum_i \begin{bmatrix} x^{(i)} x^{(i)\top} & y^{(i)} x^{(i)} \\ y^{(i)} x^{(i)\top} & y^{(i)2} \end{bmatrix}.$$

类似的计算如引理 6 的证明所得

$$\mathbf{E}[w_\star[j]C] = \lambda_j(E_{d+1,j} + E_{j,d+1}). \quad (20)$$

在这里, 因子 λ_j 来自 (A.2) 的以下推广:

$$\mathbf{E}[w_\star[j]y^{(i)}x^{(i)}[k]] = \mathbf{E}[w_\star[j]\langle w_\star, x^{(i)} \rangle x^{(i)}[k]] = \mathbf{E}[w_\star[j]^2 x^{(i)}[j]x^{(i)}[k]] = \lambda_j \mathbb{1}_{[j=k]}.$$

接下来, 我们计算 $\mathbf{E}[\langle C, E_{d+1,j} \rangle C]$ 。同样, 我们遵循与引理 6 证明中类似的计算, 只是这次我们使用以下对 (A.2) 的推广:

$$\mathbf{E}\left[\langle w_\star, x^{(i)} \rangle x^{(i)}[j] \langle w_\star, x^{(i')} \rangle x^{(i')}[j]\right] = \begin{cases} \mathbf{E}[x^{(i)}[j]^2 x^{(i')}[j]^2] = \lambda_j^2 & \text{if } i \neq i', \\ \mathbf{E}[\langle w_\star, x^{(i)} \rangle^2 x^{(i)}[j]^2] = \lambda_j \sum_k \lambda_k + 2\lambda_j^2 & \text{if } i = i', \end{cases}$$

其中最后一行成立是因为

$$\begin{aligned} \mathbf{E}\left[\langle w_\star, x^{(i)} \rangle^2 x^{(i)}[j]^2\right] &= \mathbf{E}\left[\|x^{(i)}\|^2 x^{(i)}[j]^2\right] = \mathbf{E}\left[x^{(i)}[j]^2 \sum_k x^{(i)}[k]^2\right] \\ &= \lambda_j \sum_k \lambda_k + 2\lambda_j^2. \end{aligned}$$

因此, 我们有

$$\begin{aligned} \mathbf{E}[\langle C, E_{d+1,j} \rangle C] &= \frac{1}{n^2} \cdot \left(n(n-1)\lambda_j^2 + n\lambda_j \sum_k \lambda_k + 2n\lambda_j^2 \right) (E_{d+1,j} + E_{j,d+1}) \\ &= \left(\frac{n+1}{n}\lambda_j^2 + \frac{1}{n}(\lambda_j \sum_k \lambda_k) \right) (E_{d+1,j} + E_{j,d+1}). \end{aligned} \quad (21)$$

因此, 结合 (A.3) 和 (A.3), 结果成立。 $\square$

现在我们完成了证明。由引理 6 可知

$$X_j = -\frac{1}{\frac{n+1}{n}\lambda_j + \frac{1}{n} \cdot (\sum_k \lambda_k)} E_{d+1,j}$$

是 f_j 的唯一全局最小值。因此，若 b 和 $A = [a_1 \ a_1 \ \cdots \ a_d]$ 满足条件，则它们达到 $f(b, A) = \sum_{j=1}^d f_j(b, A_j)$ 的全局最小值。

$$ba_j^\top = X_j = -\frac{1}{\frac{n+1}{n}\lambda_j + \frac{1}{n} \cdot (\sum_k \lambda_k)} E_{d+1,j} \quad \text{for all } i = 1, 2, \dots, d.$$

这可以通过以下选择实现：

$$b^\top = \mathbf{e}_{d+1}, \quad a_j = -\frac{1}{\frac{n+1}{n}\lambda_j + \frac{1}{n} \cdot (\sum_k \lambda_k)} \mathbf{e}_j \quad \text{for } i = 1, 2, \dots, d,$$

其中 $\mathbf{e}_j$ 是 j -th 坐标向量。这种选择精确对应于

$$b = \mathbf{e}_{d+1}, \quad A = -\begin{bmatrix} \text{diag}\left(\left\{\frac{1}{\frac{n+1}{n}\lambda_j + \frac{1}{n}(\sum_k \lambda_k)}\right\}_j\right) \\ 0 \end{bmatrix}.$$

Step 2: 非对角协方差情形 (定理 1 的情景)

我们最终证明定理 1 的一般结果，即 $x^{(i)}$ 从具有协方差 $\Sigma = U\Lambda U^\top$ 的高斯分布中采样，其中 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_d)$ 且 $w_\star$ 从 $\mathcal{N}(0, I_d)$ 中采样。证明通过将此情形归约为前一种情形来完成。对于每个 i ，定义 $\tilde{x}^{(i)} := U^\top x^{(i)}$ 。那么 $\mathbf{E}[\tilde{x}^{(i)}(\tilde{x}^{(i)})^\top] = \mathbf{E}[U^\top(U\Lambda U^\top)U] = \Lambda$ 。现在让我们用这种新的坐标系写出损失函数 (A.1)：由于 $x^{(i)} = U\tilde{x}^{(i)}$ ，我们有

$$f(b, A) = \mathbf{E}_{Z_0, w_\star} \left[(b^\top CA + w_\star^\top) U \tilde{x}^{(n+1)} \right]^2 = \sum_{j=1}^d \lambda_j \mathbf{E}_{Z_0, w_\star} \left[\left((b^\top CA + w_\star^\top) U \right) [j] \right]^2.$$

因此，让我们考虑向量 $(b^\top CA + w_\star^\top)U$ 。根据 C 的定义，我们有

$$\begin{aligned} (b^\top CA + w_\star^\top)U &= \frac{1}{n} \sum_i b^\top \begin{bmatrix} x^{(i)} \\ \langle x^{(i)}, w_\star \rangle \end{bmatrix}^{\otimes 2} AU + w_\star^\top U \\ &= \frac{1}{n} \sum_i b^\top \begin{bmatrix} U\tilde{x}_i \\ \langle Ux^{(i)}, w_\star \rangle \end{bmatrix}^{\otimes 2} AU + w_\star^\top U \\ &= \frac{1}{n} \sum_i b^\top \begin{bmatrix} U & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \tilde{x}_i \\ \langle Ux^{(i)}, w_\star \rangle \end{bmatrix}^{\otimes 2} \begin{bmatrix} U^\top & 0 \\ 0 & 1 \end{bmatrix} AU + w_\star^\top U \\ &= \frac{1}{n} \sum_i \tilde{b}^\top \begin{bmatrix} \tilde{x}_i \\ \langle x^{(i)}, \tilde{w}_\star \rangle \end{bmatrix}^{\otimes 2} \tilde{A} + \tilde{w}_\star^\top \end{aligned}$$

其中我们定义 $\tilde{b}^\top := b^\top \begin{bmatrix} U & 0 \\ 0 & 1 \end{bmatrix}$, $\tilde{A} := \begin{bmatrix} U^\top & 0 \\ 0 & 1 \end{bmatrix} AU$, 和 $\tilde{w}_\star := U^\top w_\star$ 。由于旋转对称性, $\tilde{w}_\star$ 也服从 $\mathcal{N}(0, I_d)$ 分布。因此, 这简化为前面的情况, 全局最小值为

$$\tilde{b} = \mathbf{e}_{d+1}, \quad \tilde{A} = - \begin{bmatrix} \text{diag} \left(\left\{ \frac{1}{\frac{n+1}{n}\lambda_j + \frac{1}{n}(\sum_k \lambda_k)} \right\}_j \right) \\ 0 \end{bmatrix}.$$

从 $\tilde{b}, \tilde{A}$ 的定义可知, 全局最小值由

$$b^\top = \mathbf{e}_{d+1}, \quad A = - \begin{bmatrix} U \text{diag} \left(\left\{ \frac{1}{\frac{n+1}{n}\lambda_i + \frac{1}{n}(\sum_k \lambda_k)} \right\}_i \right) U^\top \\ 0 \end{bmatrix},$$

按要求。

B 多层情况的证明

B.1 定理 3 的证明

证明基于概率方法 [Alon and Spencer, 2016]。根据引理 9, 目标函数可以写成 (更多细节请参见 (3) 中的推导)

$$\begin{aligned} f(A_0, A_1) &= \mathbf{E} \text{Tr} \left(\mathbf{E} \left[\prod_{i=1}^2 (I + X_0^\top A_i X_0 M) X_0^\top w_\star w_\star^\top X_0 \prod_{i=0}^1 (I + M X_0^\top A_i X_0) \right] \right) \\ &= \mathbf{E} \text{Tr} \left(\mathbf{E} \left[\prod_{i=2}^1 (I + X_0^\top A_i X_0 M) X_0^\top X_0 \prod_{j=1}^2 (I + M X_0^\top A_j X_0) \right] \right), \end{aligned}$$

其中我们利用了 $w_\star$ 的各向同性以及迹的线性性得到了最后一个方程。假设 A_0^* 和 A_1^* 表示 f 在对称矩阵上的全局极小解。由于 A_0^* 是一个对称矩阵, 它具有谱分解 $A_0^* = U D_0 U^\top$, 其中 D_0 是一个对角矩阵, U 是一个正交矩阵。值得注意的是, X_0 的分布对于正交矩阵的线性变换是不变的, 即 X_0 与 $X_0 U^\top$ 具有相同的分布。这种不变性导致

$$f(U D_0 U^\top, A_1^*) = f(D_0, U^\top A_1^* U).$$

因此, 我们可以假设 A_0^* 是对角矩阵而不失一般性。为了证明 A_1^* 也是对角矩阵, 我们利用概率论的论证。考虑一个随机的对角矩阵 S , 其对角线元素以概率 $\frac{1}{2}$ 要么是 1, 要么是 -1 。由于输入分布对于正交变换是不变的, 所以我们有

$$f(D_0, A_1^*) = f(S D_0 S, S A_1^* S) = f(D_0, S A_1^* S).$$

注意我们使用 $S D_0 S = D_0$ 在最后一个方程中, 这是由于 D_0 和 S 是对角矩阵, 且 S 在 $\{+1, -1\}$ 中有对角元素。由于 f 关于 A_1 是凸的, 直接应用 Jensen 不等式可得

$$f(D_0, A_1^*) = \mathbf{E} [f(D_0, S A_1^* S)] \geq f(D_0, \mathbf{E} [S A_1^* S]) = f(D_0, \text{diag}(A_1^*)).$$

因此, 存在对角线 D_0 和 $\mathbf{diag}(A_1^*)$, 使得对于最优的 A_0^* 和 A_1^* , $f(D_0, \mathbf{diag}(A_1^*)) \leq f(A_0^*, A_1^*)$ 成立。这完成了证明。

B.2 定理 4 的证明

让我们去掉在原始更新 (34) 中存在的因子 $\frac{1}{n}$ 。这是因为常数 $1/n$ 可以被吸收进 A_i 的中。这样做不会改变定理声明, 但可以减少符号的复杂性。

让我们考虑上下文中的损失 f 的重新表述, 如引理 9 所示。具体来说, 令 $\bar{Z}_0$ 定义为

$$\bar{Z}_0 = \begin{bmatrix} x^{(1)} & x^{(2)} & \dots & x^{(n)} & x^{(n+1)} \\ y^{(1)} & y^{(2)} & \dots & y^{(n)} & y^{(n+1)} \end{bmatrix} \in \mathbb{R}^{(d+1) \times (n+1)},$$

其中 $y^{(n+1)} = \langle w_*, x^{(n+1)} \rangle$ 。设 $\bar{Z}_i$ 表示线性 Transformer 的 $(i-1)^{th}$ 层的输出 (如 (34) 中定义, 初始化为 $\bar{Z}_0$)。在本证明的其余部分, 我们将去掉横线, 简单地将 $\bar{Z}_i$ 表示为 Z_i 。⁴ 设 $X_i \in \mathbb{R}^{d \times n+1}$ 表示 Z_i 的前 d 行, 设 $Y_i \in \mathbb{R}^{1 \times n+1}$ 表示 Z_k 的第 $(d+1)^{th}$ 行。在 (5) 中对 P_i 和 Q_i 强制的稀疏性模式下, 我们验证对于任何 $i \in \{0 \dots k\}$,

$$\begin{aligned} X_i &= X_0, \\ Y_{i+1} &= Y_i + Y_i M X_i^\top A_i X_i = Y_0 \prod_{\ell=0}^i \left(I + M X_0^\top A_\ell X_0 \right). \end{aligned} \quad (22)$$

其中 $M = \begin{bmatrix} I_{n \times n} & 0 \\ 0 & 0 \end{bmatrix}$ 。我们采用简写 $A := \{A_i\}_{i=0}^k$ 。

我们采用简写 $A = \{A_i\}_{i=0}^k$ 。设 $\mathcal{S} \subset \mathbb{R}^{(k+1) \times d \times d}$, 且 $A \in \mathcal{S}$ 当且仅当对于所有 $i \in \{0 \dots k\}$, 存在标量 $a_i \in \mathbb{R}$ 使得 $A_i = a_i \Sigma^{-1}$ 。我们用 $f(A)$ 来指代定理 4 的上下文损失, 即

$$f(A) := f \left(\left\{ Q_i = \begin{bmatrix} A_i & 0 \\ 0 & 0 \end{bmatrix}, P_i = \begin{bmatrix} 0_{d \times d} & 0 \\ 0 & 1 \end{bmatrix} \right\}_{i=0}^k \right).$$

在整个证明过程中, 我们将使用引理 9 中的 上下文损失的以下表述:

$$f(A) = \mathbf{E}_{(X_0, w_*)} \left[\text{Tr} \left((I - M) Y_{k+1}^\top Y_{k+1} (I - M) \right) \right]. \quad (23)$$

我们现在回顾定理声明:

$$\inf_{A \in \mathcal{S}} \sum_{i=0}^k \|\nabla_{A_i} f(A)\|_F^2 = 0, \quad (24)$$

其中 $\nabla_{A_i} f$ 表示关于 Frobenius 范数 $\|A_i\|_F$ 的导数。为此, 我们建立以下中间结果: 如果 $A \in \mathcal{S}$, 则对于任何 $R \in \mathbb{R}^{(k+1) \times d \times d}$, 存在 $\tilde{R} \in \mathcal{S}$, 使得在 $t = 0$ 时,

$$\frac{d}{dt} f(A + t\tilde{R}) \leq \frac{d}{dt} f(A + tR). \quad (25)$$

⁴这种使用 Z_i 的方式与 (3) 中的原始定义不同, 其中 $[Z_0]_{d+1, n+1} = 0$ 。但我们在本证明中任何地方都不会引用原始定义。

事实上，我们证明了 $\tilde{R}_i := r_i I$ ，对于 $r_i = \frac{1}{d} \text{Tr}(\Sigma^{1/2} R_i \Sigma^{1/2})$ 。这通过以下简单的论证得出 (5)：考虑 “ $\mathcal{S}$ -约束梯度流”：令 $A(t) : \mathbb{R}^+ \rightarrow \mathbb{R}^{(k+1) \times d \times d}$ 被定义为

$$\frac{d}{dt} A_i(t) = -r_i(t) \Sigma^{-1}, \quad r_i(t) := \text{Tr}(\Sigma^{1/2} \nabla_{A_i} f(A(t)) \Sigma^{1/2})$$

对于 $i = 0 \dots k$ 。通过 (6)，我们验证了

$$\frac{d}{dt} f(A(t)) \leq - \sum_{i=0}^k \|\nabla_{A_i} f(A(t))\|_F^2. \quad (26)$$

我们从定义验证得出 $f(A) \geq 0$ ；如果 (5) 中的下确界不能为零，则不等式 (7) 将确保当 $t \rightarrow \infty$ 时出现无界的下降，这与 $f(A)$ 是有下界的事实相矛盾。这完成了证明。

Step 0: 证明概要

证明的其余部分将用于证明公式(6)中的不等式，其概述如下：

- 在步骤 1 中，我们将(6)中的不等式条件简化为一个更容易验证的逐层条件。具体来说，我们只需要验证当 R_i 全部为零，除了某个固定的 j 的 R_j 时，(6)中的不等式是否成立（见(8)中的更简单条件）

在步骤 1 结束时，我们建立了一些额外的符号，并引入了一个重要的矩阵 G ，它大致是“注意力层矩阵的乘积”。在方程块(9)中，当 $A(t)$ 朝着 R 的方向移动时，我们开始分析 $\frac{d}{dt} f(A(t))$ ，因为 X_0 （大致来说）是随机变换的。

- 在步骤 2 中，我们 G （见 (10)）和 $\frac{d}{dt} G(A(t))$ （见 (11)）在 X_0 的随机变换下。(11) 中的想法是“随机变换 X_0 ”的效果与“随机变换 R ”相同（回忆 R 是对 A 的扰动）。
- 在步骤 3 中，我们将步骤 2 的结果应用于 $\frac{d}{dt} f(A(t))$ 在(9)中的表达式。我们验证了 $\tilde{R}$ 在(6)中确实是“随机变换 R ”后所期望的矩阵。这完成了我们的证明。

Step 1: 转化为逐层条件

要证明公式(6)中的不等式，只需证明以下更简单的条件：设 $j \in \{0 \dots k\}$ 。设 $R_j \in \mathbb{R}^{d \times d}$ 为任意矩阵。对于 $C \in \mathbb{R}^{d \times d}$ ，令 $A(tC, j)$ 表示矩阵的集合，其中 $[A(tC, j)]_j = A_j + tC$ ，而对于 $i \neq j$ ， $[A(tC, j)]_i = A_i$ 。我们证明，对于所有 $j \in \{0 \dots k\}$ ， $R_j \in \mathbb{R}^{d \times d}$ ，存在 $\tilde{R}_j = r_j \Sigma^{-1}$ ，使得在 $t = 0$ 时

$$\frac{d}{dt} f(A(t\tilde{R}_j, j)) \leq \frac{d}{dt} f(A(tR_j, j)) \quad (27)$$

我们可以验证，证明对于所有的 j 有 (8) 等价于证明不等式 (6)，注意到对于任意的 $R \in \mathbb{R}^{(k+1) \times d \times d}$ ，在 $t = 0$ 处，有 $\frac{d}{dt} f(A + tR) = \sum_{j=0}^k \frac{d}{dt} f(A(tR_j, j))$ 。现在我们将着手证明对于某个任意选取但在整个过程中保持固定的指标 j 有 (8)。

由 Y_{i+1} 在 (3) 上的动力学以及 $f(A)$ 在 (4) 中的定义,

$$\begin{aligned}
& f(A(tR_j, j)) \\
&= \mathbf{E} \left[\text{Tr} \left((I - M) Y_{k+1}^\top Y_{k+1} (I - M) \right) \right] \\
&= \mathbf{E} \left[\text{Tr} \left((I - M) G(X_0, A_j + tR_j)^\top w_\star^\top w_\star G(X_0, A_j + tR_j) (I - M) \right) \right] \\
&= \mathbf{E} \left[\text{Tr} \left((I - M) G(X_0, A_j + tR_j)^\top \Sigma^{-1} G(X_0, A_j + tR_j) (I - M) \right) \right]
\end{aligned}$$

其中 $G(X, A_j + C) := X \prod_{i=0}^k (I - MX^\top [A(tC, j)]_i X)$ 。第二个等式来自于将 Y_{k+1} 的表达式代入 (3)。对于本证明的其余部分, 令 U 表示一个均匀随机采样的正交矩阵。令 $U_\Sigma := \Sigma^{1/2} U \Sigma^{-1/2}$ 。利用 $X_0 \stackrel{d}{=} U_\Sigma X_0$ 的事实, 我们可以验证

$$\begin{aligned}
& \left. \frac{d}{dt} f(A(tR_j, j)) \right|_{t=0} \\
&= \left. \frac{d}{dt} \mathbf{E} \left[\text{Tr} \left((I - M) G(X_0, A_j + tR_j)^\top \Sigma^{-1} G(X_0, A_j + tR_j) (I - M) \right) \right] \right|_{t=0} \\
&= \left. \frac{d}{dt} \mathbf{E}_{X_0, U} \left[\text{Tr} \left((I - M) G(U_\Sigma X_0, A_j + tR_j)^\top \Sigma^{-1} G(U_\Sigma X_0, A_j + tR_j) (I - M) \right) \right] \right|_{t=0} \\
&= 2 \mathbf{E}_{X_0, U} \left[\text{Tr} \left((I - M) G(U_\Sigma X_0, A_j)^\top \Sigma^{-1} \left. \frac{d}{dt} G(U_\Sigma X_0, A_j + tR_j) \right|_{t=0} (I - M) \right) \right]. \quad (28)
\end{aligned}$$

Step 2: G 和 $\frac{d}{dt}G$ 在 X_0 的随机变换下

我们现在验证 $G(U_\Sigma X_0, A_j) = U_\Sigma G(X_0, A_j)$:

$$\begin{aligned}
& G(U_\Sigma X_0, A_j) \\
&= U_\Sigma X_0 \prod_{i=0}^k \left(I + M X_0^\top U_\Sigma^\top A_i U_\Sigma X_0 \right) \\
&= U_\Sigma G(X_0, A_j), \quad (29)
\end{aligned}$$

其中我们利用了 $U_\Sigma^\top A_i U_\Sigma = U_\Sigma^\top (a_i \Sigma^{-1}) U_\Sigma = A_i$ 。接下来, 我们验证

$$\begin{aligned}
\frac{d}{dt} G(U_\Sigma X_0, R_j) &= U_\Sigma X_0 \left(\prod_{i=0}^{j-1} (I + M X_0^\top A_i X_0) \right) M X_0^\top U_\Sigma^\top R_j U_\Sigma X_0 \prod_{i=j+1}^k (I + M X_0^\top A_i X_0) \\
&= U_\Sigma \frac{d}{dt} G(X_0, U_\Sigma^\top R_j U_\Sigma) \quad (30)
\end{aligned}$$

其中第一个等号再次利用了 $U_\Sigma^\top A_i U_\Sigma = A_i$ 的事实。

Step 3: 将所有内容综合起来

让我们继续从 (9) 开始。将 (10) 和 (11) 代入 (9) 中,

$$\left. \frac{d}{dt} f(A(tR_j, j)) \right|_{t=0}$$

$$\begin{aligned}
&= 2\mathbf{E}_{X_0, U} \left[\text{Tr} \left((I - M) G(U_\Sigma X_0, A_j)^\top \Sigma^{-1} \frac{d}{dt} G(U_\Sigma X_0, A_j + tR_j) \Big|_{t=0} (I - M) \right) \right] \\
&\stackrel{(i)}{=} 2\mathbf{E}_{X_0, U} \left[\text{Tr} \left((I - M) G(X_0, A_j)^\top \Sigma^{-1} \frac{d}{dt} G(X_0, A_j + tU_\Sigma^\top R_j U_\Sigma) \Big|_{t=0} (I - M) \right) \right] \\
&= 2\mathbf{E}_{X_0} \left[\text{Tr} \left((I - M) G(X_0, A_j)^\top \Sigma^{-1} \mathbf{E}_U \left[\frac{d}{dt} G(X_0, A_j + tU_\Sigma^\top R_j U_\Sigma) \Big|_{t=0} \right] (I - M) \right) \right] \\
&\stackrel{(ii)}{=} 2\mathbf{E}_{X_0} \left[\text{Tr} \left((I - M) G(X_0, A_j)^\top \Sigma^{-1} \frac{d}{dt} G(X_0, A_j + t\mathbf{E}_U [U_\Sigma^\top R_j U_\Sigma]) \Big|_{t=0} (I - M) \right) \right] \\
&= 2\mathbf{E}_{X_0} \left[\text{Tr} \left((I - M) G(X_0, A_j)^\top \Sigma^{-1} \frac{d}{dt} G(X_0, A_j + t \cdot r_j \Sigma^{-1}) \Big|_{t=0} (I - M) \right) \right] \\
&= \frac{d}{dt} f(A(t \cdot r_j \Sigma^{-1}, j)) \Big|_{t=0},
\end{aligned}$$

其中 $r_j := \frac{1}{d} \text{Tr}(\Sigma^{1/2} R_j \Sigma^{1/2})$ 。在上面, (i) 使用 (10) 和 (11), 以及 $U_\Sigma^\top \Sigma^{-1} U_\Sigma = \Sigma^{-1}$ 的事实。(ii) 使用 $\frac{d}{dt} G(X_0, A_j + tC) \Big|_{t=0}$ 关于 C 是仿射的这一事实。要看到这一点, 可以验证 G 的定义, 例如使用与 (11) 类似的代数, 可知 $\frac{d}{dt} G(X_0, A_j + C)$ 关于 C 是仿射的。因此 $\mathbf{E}_U [G(X_0, A_j + tU_\Sigma^\top R_j U_\Sigma)] = G(X_0, A_j + t\mathbf{E}_U [U_\Sigma^\top R_j U_\Sigma])$ 。

B.3 定理 5 的证明

定理 5 的证明与定理 4 的证明类似, 并且设置也类似。然而为了保持证明的自包含性, 我们将重新陈述设置。再次说明, 我们省略了在原始更新 (34) 中存在的因子 $\frac{1}{n}$ 。这是因为常数 $1/n$ 可以被吸收进 A_i 中。这样做不会改变定理声明, 但可以减少符号的复杂性。

让我们考虑上下文中的损失 f 的重新表述, 如引理 9 所示。具体来说, 令 $\bar{Z}_0$ 定义为

$$\bar{Z}_0 = \begin{bmatrix} x^{(1)} & x^{(2)} & \dots & x^{(n)} & x^{(n+1)} \\ y^{(1)} & y^{(2)} & \dots & y^{(n)} & y^{(n+1)} \end{bmatrix} \in \mathbb{R}^{(d+1) \times (n+1)},$$

其中 $y^{(n+1)} = \langle w_\star, x^{(n+1)} \rangle$ 。设 $\bar{Z}_i$ 表示线性 Transformer 的 $(i-1)^{th}$ 层的输出 (如 (34) 中定义, 初始化为 $\bar{Z}_0$)。在本证明的其余部分, 我们将去掉横线, 简单地将 $\bar{Z}_i$ 表示为 Z_i 。⁵ 设 $X_i \in \mathbb{R}^{d \times n+1}$ 表示 Z_i 的前 d 行, 设 $Y_i \in \mathbb{R}^{1 \times n+1}$ 表示 Z_i 的第 $(d+1)^{th}$ 行。在 (6) 中强制的稀疏性模式下, 我们验证对于任何 $i \in \{0 \dots k\}$,

$$\begin{aligned}
X_{i+1} &= X_i + B_i X_i M X_i^\top A_i X_i \\
Y_{i+1} &= Y_i + Y_i M X_i^\top A_i X_i = Y_0 \prod_{\ell=0}^i \left(I + M X_\ell^\top A_\ell X_\ell \right). \tag{31}
\end{aligned}$$

我们采用简写 $A = \{A_i\}_{i=0}^k$ 和 $B = \{B_i\}_{i=0}^k$ 。令 $\mathcal{S} \subset \mathbb{R}^{2 \times (k+1) \times d \times d}$ 定义如下: $(A, B) \in \mathcal{S}$ 当且仅当对于所有的 $i \in \{0 \dots k\}$, 存在标量 $a_i, b_i \in \mathbb{R}$ 使得 $A_i = a_i \Sigma^{-1}$ 和 $B_i = b_i I$ 。在整个证明过程中, 我们将使用引理 9 中关于上下文损失的以下表述:

$$f(A, B) := \mathbf{E}_{(X_0, w_\star)} \left[\text{Tr} \left((I - M) Y_{k+1}^\top Y_{k+1} (I - M) \right) \right]. \tag{32}$$

⁵ 这种使用 Z_i 的方式与 (3) 中的原始定义不同。但我们不会在本证明中的任何地方引用原始定义。

(注意, Z_0 中的唯一随机性来自于 X_0 和 $w_\star$, 因为 Y_0 是 X_0 和 $w_\star$ 的确定性函数)。我们现在回顾定理声明:

$$\inf_{(A,B) \in \mathcal{S}} \sum_{i=0}^k \|\nabla_{A_i} f(A, B)\|_F^2 + \|\nabla_{B_i} f(A, B)\|_F^2 = 0 \quad (33)$$

其中 $\nabla_{A_i} f$ 表示关于 Frobenius 范数 $\|A_i\|_F$ 的导数。

我们的目标是证明, 如果 $(A, B) \in \mathcal{S}$, 那么对于任何 $(R, S) \in \mathbb{R}^{2 \times (k+1) \times d \times d}$, 存在 $(\tilde{R}, \tilde{S}) \in \mathcal{S}$, 使得在 $t = 0$ 时

$$\frac{d}{dt} f(A + t\tilde{R}, B + t\tilde{S}) \leq \frac{d}{dt} f(A + tR, B + tS). \quad (34)$$

事实上, 我们证明了 $\tilde{R}_i := r_i I$, 对于 $r_i = \frac{1}{d} \text{Tr}(\Sigma^{1/2} R_i \Sigma^{1/2})$ 和 $\tilde{S}_i = s_i I$, 对于 $s_i = \frac{1}{d} \text{Tr}(\Sigma^{-1/2} S_i \Sigma^{1/2})$ 。这说明在 (14) 中的下确界为零, 这是通过以下简单论证: 考虑 “ $\mathcal{S}$ -约束梯度流”: 令 $A(t) : \mathbb{R}^+ \rightarrow \mathbb{R}^{(k+1) \times d \times d}$ 和 $B(t) : \mathbb{R}^+ \rightarrow \mathbb{R}^{(k+1) \times d \times d}$ 定义为

$$\begin{aligned} \frac{d}{dt} A_i(t) &= -r_i(t) \Sigma^{-1}, \quad r_i(t) := \text{Tr}(\Sigma^{1/2} \nabla_{A_i} f(A(t), B(t)) \Sigma^{1/2}) \\ \frac{d}{dt} B_i(t) &= -s_i(t) \Sigma^{-1}, \quad s_i(t) := \text{Tr}(\Sigma^{-1/2} \nabla_{B_i} f(A(t), B(t)) \Sigma^{1/2}), \end{aligned}$$

对于 $i = 0 \dots k$ 。根据 (15) 中的不等式, 我们验证了

$$\frac{d}{dt} f(A(t), B(t)) \leq - \left(\sum_{i=0}^k \|\nabla_{A_i} f(A(t), B(t))\|_F^2 + \|\nabla_{B_i} f(A(t), B(t))\|_F^2 \right). \quad (35)$$

我们从定义验证得到 $f(A, B) \geq 0$; 如果 (14) 中的下确界不成立, 则不等式 (16) 将确保当 $t \rightarrow \infty$ 时出现无界下降, 这与 $f(A, B) \geq 0$ 的事实矛盾。证明结束。

Step 0: 证明概要

证明的其余部分将用于证明公式(15)中的不等式, 其概述如下:

- 在步骤 1 中, 我们将(15)中的条件简化为一个更容易验证的逐层条件。具体来说, 我们只需要在两种情况中的一种中验证(15): (I) 当 R_i, S_i 均为零, 除了对于某个固定的 j 而言的 R_j (见(18)), 或者 (II) 当 R_i, S_i 均为零, 除了对于某个固定的 j 而言的 S_j (见(17))。

我们专注于证明 (II), 因为证明 (I) 几乎相同。在步骤 1 的最后, 我们建立了一些额外的符号, 并引入了一个重要的矩阵 G , 它大致是 “注意力层矩阵的乘积”。在 (19) 中, 我们研究当 $B(t)$ 沿着 S 的方向移动时 $f(A, B(t))$ 的演化过程, 因为 X_0 被随机变换。这促使了下面步骤 2 和步骤 3 的后续分析。

- 在步骤 2 中, 我们研究当 X_0 随机变换时, 每一层 (X_i 和 Y_i 从 (12)) 的输出如何变化。这里有两个感兴趣的结果: 首先我们在(20)中提供了 X_i 的表达式。其次, 我们在(21)中提供了 $\frac{d}{dt} X_i(B(t))$ 的表达式。

- 在步骤 3 中，我们使用步骤 2 的结果来研究 G （参见 (25)）和 $\frac{d}{dt}G(B(t))$ （参见 (26)）在 X_0 的随机变换下的表现。这一步的想法是证明“对 X_0 进行随机变换”与“对 S 进行随机变换”具有相同的效果（参见 S 是对 B 的扰动）。
- 在步骤 4 中，我们使用步骤 2 和步骤 3 的结果来表达 $\frac{d}{dt}f(A, B(t))$ 在 (19) 中。我们验证了 $\tilde{S}$ 在 (18) 中确实是“随机变换 S ”后所期望的矩阵。这完成了对 (II) 的证明。
- 在步骤 5 中，我们概述了 (I) 的证明，这与我们在步骤 2-4 中展示的 (II) 的证明几乎相同。

Step 1: 转化为逐层条件

为了证明公式(15)中的不等式，只需证明以下更简单的条件：设 $j \in \{0 \dots k\}$ 。设 $R_j, S_j \in \mathbb{R}^{d \times d}$ 为任意矩阵。对于 $C \in \mathbb{R}^{d \times d}$ ，令 $A(tC, j)$ 表示矩阵的集合，其中 $A(tC, j)_j = A_j + tC$ ，而对于 $i \neq j$ ， $A(tC, j)_i = A_i$ 。类似地定义 $B(tC, j)$ 。我们证明对于所有 $j \in \{0 \dots k\}$ 和所有 $R_j, S_j \in \mathbb{R}^{d \times d}$ ，存在 $\tilde{R}_j = r_j \Sigma^{-1}$ 和 $\tilde{S}_j = s_j \Sigma^{-1}$ ，使得在 $t = 0$ 时，

$$\frac{d}{dt}f(A(t\tilde{R}_j, j), B) \leq \frac{d}{dt}f(A(tR_j, j), B) \quad (36)$$

$$\text{and} \quad \frac{d}{dt}f(A, B(t\tilde{S}_j, j)) \leq \frac{d}{dt}f(A, B(tS_j, j)). \quad (37)$$

我们可以验证 (15) 等同于 (17)+(18)，这是通过注意到对于任何 $(R, S) \in \mathbb{R}^{2 \times (k+1) \times d \times d}$ ，在 $t = 0$ ， $\frac{d}{dt}f(A + tR, B + tS) = \sum_{j=0}^k \left(\frac{d}{dt}f(A(tR_j, j), B) + \frac{d}{dt}f(A, B(tS_j, j)) \right)$ 。

我们首先专注于证明 (18) ((17) 的证明类似，我们在最后的第 5 步中给出)，其中某个索引 j 是任意选择但在整个过程中固定的。注意，在 (12) 中的动力学下， X_i 和 Y_i 实际上是 A, B 和 X_0 的函数。在我们随后的大部分讨论中， A_i （对于所有 i ）和 B_i （对于所有 $i \neq j$ ）可以被视为常数矩阵。然而，我们会明确说明对 X_0 和 B_j 的依赖性（当我们考虑曲线 $B_j + tS$ 时），即我们使用 $X_i(X, C)$ （或 $Y_i(X, C)$ ）来表示在 (12) 动力学下，从 $X_0 = X$ 初始化并具有 $B_j = C$ 时 X_i （或 Y_i ）的值。

由 (12) 中的动力学和 f 在 (13) 中的定义，

$$\begin{aligned} & f(A, B(tS_j, j)) \\ &= \mathbf{E} \left[\text{Tr} \left((I - M) Y_{k+1}(X_0, B_j + tS)^\top Y_{k+1}(X_0, B_j + tS_j) (I - M) \right) \right] \\ &= \mathbf{E} \left[\text{Tr} \left((I - M) G(X_0, B_j + tS_j)^\top w_\star^\top w_\star G(X_0, B_j + tS_j) (I - M) \right) \right] \\ &= \mathbf{E} \left[\text{Tr} \left((I - M) G(X_0, B_j + tS_j)^\top \Sigma^{-1} G(X_0, B_j + tS_j) (I - M) \right) \right] \end{aligned}$$

其中 $G(X, C) := X \prod_{i=0}^k (I - M X_i(X, C)^\top A_i X_i(X, C))$ 。第二个等式来源于代入 (12)。

对于本证明的其余部分，令 U 表示一个均匀随机采样的正交矩阵。令 $U_\Sigma := \Sigma^{1/2} U \Sigma^{-1/2}$ 。利

用 $X_0 \stackrel{d}{=} U_\Sigma X_0$ 的事实，我们可以从基本微积分中验证出

$$\begin{aligned}
& \left. \frac{d}{dt} f(A, B(tS_j, j)) \right|_{t=0} \\
&= \frac{d}{dt} \mathbf{E}_{X_0} \left[\text{Tr} \left((I - M) G(X_0, B_j + tS_j)^\top \Sigma^{-1} G(X_0, B_j + tS_j) (I - M) \right) \right] \Big|_{t=0} \\
&= \frac{d}{dt} \mathbf{E}_{X_0, U} \left[\text{Tr} \left((I - M) G(U_\Sigma X_0, B_j + tS_j)^\top \Sigma^{-1} G(U_\Sigma X_0, B_j + tS_j) (I - M) \right) \right] \Big|_{t=0} \\
&= 2 \mathbf{E}_{X_0, U} \left[\text{Tr} \left((I - M) G(U_\Sigma X_0, B_j)^\top \Sigma^{-1} \frac{d}{dt} G(U_\Sigma X_0, B_j + tS_j) \Big|_{t=0} (I - M) \right) \right]. \quad (38)
\end{aligned}$$

Step 2: X_i 和 $\frac{d}{dt} X_i$ 在 X_0 的随机变换下

在此步骤中，我们证明当 X_0 被 U_Σ 变换时， X_i 对 $i \geq 1$ 的变换也是以一种简单的方式进行的。此步骤的第一个目标是证明

$$X_i(U_\Sigma X_0, B_j) = U_\Sigma X_i(X_0, B_j). \quad (39)$$

我们通过归纳法来证明这一点。当 $i = 0$ 时，这显然由定义成立。假设对于某个 i ，(20) 成立。那么

$$\begin{aligned}
& X_{i+1}(U_\Sigma X_0, B_j) \\
&= X_i(U_\Sigma X_0, B_j) + B_i X_i(U_\Sigma X_0, B_j) M X_i(U_\Sigma X_0, B_j)^\top A_i X_i(U_\Sigma X_0, B_j) \\
&= U_\Sigma X_i(X_0, B_j) + U_\Sigma B_i X_i(X_0, B_j) M X_i(X_0, B_j)^\top A_i X_i(X_0, B_j) \\
&= U_\Sigma X_{i+1}(X_0, B_j)
\end{aligned}$$

其中第二个等式使用了归纳假设，以及事实 $A_i = a_i \Sigma^{-1}$ ，从而得到 $U_\Sigma^\top A_i U_\Sigma = A_i$ ，并且事实 $B_i = b_i I$ ，这是由 $\mathcal{S}$ 的定义以及我们假设 $(A, B) \in \mathcal{S}$ 得到的。这完成了 (20) 的证明。

我们现在呈现此步骤的第二个主要结果。令 $U_\Sigma^{-1} := \Sigma^{1/2} U^\top \Sigma^{-1/2}$ ，以便它满足 $U_\Sigma U_\Sigma^{-1} = U_\Sigma^{-1} U_\Sigma = I$ 。对于所有 i ，

$$U_\Sigma^{-1} \frac{d}{dt} X_i(U_\Sigma X_0, B_j + tS_j) \Big|_{t=0} = \frac{d}{dt} X_i(X_0, B_j + tU_\Sigma^{-1} S_j U_\Sigma) \Big|_{t=0}. \quad (40)$$

为简化表示，我们在后续证明中将不再显式写出 $\cdot|_{t=0}$ 。我们首先写出 (21) 右边项的动力学方

程：从 (12) 中 X_i 的动力学方程可知，对于任何 $\ell \leq j$ ，以及任何 $i \geq j+1$ ，以及任何 $C \in \mathbb{R}^{d \times d}$ ，

$$\begin{aligned}
\frac{d}{dt} X_\ell (X_0, B_j + tC) &= 0 \\
\frac{d}{dt} X_{j+1} (X_0, B_j + tC) &= CX_j (X_0, B_j) M X_j (X_0, B_j)^\top A_j X_j (X_0, B_j) \\
\frac{d}{dt} X_{i+1} (X_0, B_j + tC) &= \frac{d}{dt} X_i (X_0, B_j + tC) \\
&\quad + B_i \left(\frac{d}{dt} X_i (X_0, B_j + tC) \right) M X_i (X_0, B_j)^\top A_i X_i (X_0, B_j) \\
&\quad + B_i X_i (X_0, B_j) M \left(\frac{d}{dt} X_i (X_0, B_j + tC) \right)^\top A_i X_i (X_0, B_j) \\
&\quad + B_i X_i (X_0, B_j) M X_i (X_0, B_j)^\top A_i \left(\frac{d}{dt} X_i (X_0, B_j + tC) \right) \quad (41)
\end{aligned}$$

我们现在已经准备好使用归纳法证明 (21)。对于基本情况，我们验证当 $\ell \leq j$ 时， $U_\Sigma^{-1} \frac{d}{dt} X_\ell (U_\Sigma X_0, B_k + tS_j) = 0 = \frac{d}{dt} X_\ell (X_0, B_j + tU_\Sigma^{-1} S_j U_\Sigma)$ （参见 (22) 中的第一个方程）。对于索引 $j+1$ ，我们验证 that

$$\begin{aligned}
U_\Sigma^{-1} \frac{d}{dt} X_{j+1} (U_\Sigma X_0, B_j + tS_j) &= U_\Sigma^{-1} S_j U_\Sigma X_j (X_0, B_j) M X_j (U_\Sigma X_0, B_j)^\top A_j \\
&= \frac{d}{dt} X_{j+1} (U_\Sigma X_0, B_j + tU_\Sigma^{-1} S_j U_\Sigma X_j) \quad (42)
\end{aligned}$$

其中我们使用两个事实：1. 从 $X_i(U_\Sigma X_0, B_j) = U_\Sigma X_i(X_0, B_j)$ 得到 (20)，2. $A_i = a_i \Sigma^{-1}$ ，从而得到 $U_\Sigma^\top A_i U_\Sigma = A_i$ 。我们通过与 (22) 中的第二个方程比较来验证 $U_\Sigma^{-1} \frac{d}{dt} X_j (U_\Sigma X_0, B_j + tS_j) = 0 = \frac{d}{dt} X_j (X_0, B_j + tU_\Sigma^{-1} S_j U_\Sigma)$ 。这些结论完成了基础情况的证明。

现在假设对于某个 i ，(21) 成立。我们现在将证明对于 $i+1$ ，(21) 成立。由 (12)，

$$\begin{aligned}
&U_\Sigma^{-1} \frac{d}{dt} X_{i+1} (U_\Sigma X_0, B_j + tS_j) \\
&= U_\Sigma^{-1} \frac{d}{dt} (X_i (U_\Sigma X_0, B_j + tS_j)) \\
&\quad + U_\Sigma^{-1} \frac{d}{dt} \left(B_i X_i (U_\Sigma X_0, B_j + tS_j) M X_i (U_\Sigma X_0, B_j + tS_j)^\top A_i X_i (U_\Sigma X_0, B_j + tS_j) \right) \\
&= U_\Sigma^{-1} \frac{d}{dt} (X_i (U_\Sigma X_0, B_j + tS_j)) \\
&\quad + U_\Sigma^{-1} B_i \left(\frac{d}{dt} X_i (U_\Sigma X_0, B_j + tS_j) \right) M X_i (U_\Sigma X_0, B_j)^\top A_i X_i (U_\Sigma X_0, B_j) \\
&\quad + U_\Sigma^{-1} B_i X_i (U_\Sigma X_0, B_j) M \left(\frac{d}{dt} X_i (U_\Sigma X_0, B_j + tS_j) \right)^\top A_i X_i (U_\Sigma X_0, B_j) \\
&\quad + U_\Sigma^{-1} B_i X_i (U_\Sigma X_0, B_j) M X_i (U_\Sigma X_0, B_j)^\top A_i \left(\frac{d}{dt} X_i (U_\Sigma X_0, B_j + tS_j) \right) \\
&\stackrel{(i)}{=} U_\Sigma^{-1} \frac{d}{dt} X_i (U_\Sigma X_0, B_j + tS_j) \\
&\quad + B_i \left(U_\Sigma^{-1} \frac{d}{dt} X_i (U_\Sigma X_0, B_j + tS_j) \right) M X_i (X_0, B_j)^\top A_i X_i (X_0, B_j) \\
&\quad + B_i X_i (X_0, B_j) M \left(U_\Sigma^{-1} \frac{d}{dt} X_i (U_\Sigma X_0, B_j + tS_j) \right)^\top A_i X_i (X_0, B_j)
\end{aligned}$$

$$\begin{aligned}
& + B_i X_i(X_0, B_j) M X_i(X_0, B_j)^\top A_i \left(U_\Sigma^{-1} \frac{d}{dt} X_i(U_\Sigma X_0, B_j + t S_j) \right) \\
& \stackrel{(ii)}{=} \frac{d}{dt} X_i(X_0, B_j + t U_\Sigma^{-1} S_j U_\Sigma) \\
& + B_i \left(\frac{d}{dt} X_i(X_0, B_j + t U_\Sigma^{-1} S_j U_\Sigma) \right) M X_i(X_0, B_j)^\top A_i X_i(X_0, B_j) \\
& + B_i X_i(X_0, B_j) M \left(\frac{d}{dt} X_i(X_0, B_j + t U_\Sigma^{-1} S_j U_\Sigma) \right)^\top A_i X_i(X_0, B_j) \\
& + B_i X_i(X_0, B_j) M X_i(X_0, B_j)^\top A_i \left(\frac{d}{dt} X_i(X_0, B_j + t U_\Sigma^{-1} S_j U_\Sigma) \right)
\end{aligned} \tag{43}$$

在 (i) 以上, 我们关键地使用了以下事实: 1. $B_i = b_i I$ 使得 $U_\Sigma^{-1} B_i = B_i U_\Sigma^{-1}$, 2. $X_i(U_\Sigma X_0, B_j) = U_\Sigma X_i(X_0, B_j)$ 来自 (20), 3. $A_i = a_i \Sigma^{-1}$, 使得 $U_\Sigma^\top A_i U_\Sigma = A_i$, 4. $U_\Sigma U_\Sigma^{-1} = U_\Sigma^{-1} U_\Sigma = I$ 。(ii) 来自我们的归纳假设。通过验证当 $C = U_\Sigma^{-1} S U_\Sigma$ 时 (24) 确切地匹配 (22) 的第三个方程, 归纳证明就完成了。

Step 3: G 和 $\frac{d}{dt}G$ 在 X_0 的随机变换下

我们现在验证 $G(U_\Sigma X_0, B_j) = U_\Sigma G(X_0, B_j)$ 。这是 (20) 中等价关系的直接结果, 因为

$$\begin{aligned}
& G(U_\Sigma X_0, B_j) \\
& = U_\Sigma X_0 \prod_{i=0}^k \left(I + M X_i(U_\Sigma X_0, B_j)^\top A_i X_i(U_\Sigma X_0, B_j) \right) \\
& = U_\Sigma X_0 \prod_{i=0}^k \left(I + M X_i(X_0, B_j)^\top A_i X_i(X_0, B_j) \right) \\
& = U_\Sigma G(X_0, B_j),
\end{aligned} \tag{44}$$

其中第二个等式使用了 (20), 以及 $U_\Sigma^\top A_i U_\Sigma = A_i$ 的事实。接下来, 我们将证明

$$U_\Sigma^{-1} \frac{d}{dt} G(U_\Sigma X_0, B_j + t S_j) \Big|_{t=0} = \frac{d}{dt} G(X_0, B_j + t U_\Sigma^{-1} S_j U_\Sigma) \Big|_{t=0}. \tag{45}$$

要看到这一点, 我们可以展开

$$\begin{aligned}
& U_\Sigma^{-1} \frac{d}{dt} G(U_\Sigma X_0, B_j + t S_j) \\
& = U_\Sigma^{-1} \frac{d}{dt} \left(U_\Sigma X_0 \prod_{i=0}^k \left(I + M X_i(U_\Sigma X_0, B_j + t S_j)^\top A_i X_i(U_\Sigma X_0, B_j + t S_j) \right) \right) \\
& = X_0 \sum_{i=0}^k \left(\prod_{\ell=0}^{i-1} \left(I + M X_\ell(U_\Sigma X_0, B_j)^\top A_\ell X_\ell(U_\Sigma X_0, B_\ell) \right) \right) \\
& \quad \cdot M \frac{d}{dt} \left(X_i(U_\Sigma X_0, B_j + t S_j)^\top A_i X_i(U_\Sigma X_0, B_j) \right) \\
& \quad \cdot \left(\prod_{\ell=i+1}^k \left(I + M X_\ell(U_\Sigma X_0, B_j)^\top A_\ell X_\ell(U_\Sigma X_0, B_\ell) \right) \right)
\end{aligned}$$

$$\begin{aligned}
& \stackrel{(i)}{=} X_0 \sum_{i=0}^k \left(\prod_{\ell=0}^{i-1} \left(I + M X_\ell(X_0, B_j)^\top A_\ell X_\ell(X_0, B_\ell) \right) \right) \\
& \quad \cdot M \left(\left(U_\Sigma^{-1} \frac{d}{dt} X_i(U_\Sigma X_0, B_j + t S_j) \right)^\top A_i X_i(X_0, B_j) + M X_i(X_0, B_j)^\top A_i \left(U_\Sigma^{-1} \frac{d}{dt} X_i(U_\Sigma X_0, B_j + t S_j) \right) \right) \\
& \quad \cdot \left(\prod_{\ell=i+1}^k \left(I + M X_\ell(X_0, B_j)^\top A_\ell X_\ell(X_0, B_\ell) \right) \right) \\
& \stackrel{(ii)}{=} X_0 \sum_{i=0}^k \left(\prod_{\ell=0}^{i-1} \left(I + M X_\ell(X_0, B_j)^\top A_\ell X_\ell(X_0, B_\ell) \right) \right) \\
& \quad \cdot M \left(\left(\frac{d}{dt} X_i(X_0, B_j + t U_\Sigma^{-1} S_j U_\Sigma) \right)^\top A_i X_i(X_0, B_j) + M X_i(X_0, B_j)^\top A_i \left(\frac{d}{dt} X_i(X_0, B_j + t U_\Sigma^{-1} S_j U_\Sigma) \right) \right) \\
& \quad \cdot \left(\prod_{\ell=i+1}^k \left(I + M X_\ell(X_0, B_j)^\top A_\ell X_\ell(X_0, B_\ell) \right) \right) \\
& \stackrel{(iii)}{=} \frac{d}{dt} G(X_0, B_j + t U_\Sigma^{-1} S_j U_\Sigma)
\end{aligned}$$

在 (i) 上面, 我们有以下事实: 1. $X_i(U_\Sigma X_0, B_j) = U_\Sigma X_i(X_0, B_j)$ 来自 (20), 2. $A_i = a_i \Sigma^{-1}$, 使得 $U_\Sigma^\top A_i U_\Sigma = A_i$, 3. $U_\Sigma U_\Sigma^{-1} = U_\Sigma^{-1} U_\Sigma = I$ 。(ii) 来自 (21)。(iii) 是 G 的定义。

Step 4: 将所有内容综合起来

让我们现在从 (19) 继续。我们现在可以将从 (25) 和 (26) 得到的 G 和 $\frac{d}{dt} G$ 的新表达式代入 (19) 中:

$$\begin{aligned}
& \left. \frac{d}{dt} f(A, B(t S_j, j)) \right|_{t=0} \\
& = 2\mathbf{E}_{X_0, U} \left[\text{Tr} \left((I - M) G(U_\Sigma X_0, B_j)^\top \Sigma^{-1} \frac{d}{dt} G(U_\Sigma X_0, B_j + t S_j) \Big|_{t=0} (I - M) \right) \right] \\
& \stackrel{(i)}{=} 2\mathbf{E}_{X_0, U} \left[\text{Tr} \left((I - M) G(X_0, B_j)^\top \Sigma^{-1} \frac{d}{dt} G(X_0, B_j + t U_\Sigma^{-1} S_j U_\Sigma) \Big|_{t=0} (I - M) \right) \right] \\
& = 2\mathbf{E}_{X_0} \left[\text{Tr} \left((I - M) G(X_0, B_j)^\top \Sigma^{-1} \mathbf{E}_U \left[\frac{d}{dt} G(X_0, B_j + t U_\Sigma^{-1} S_j U_\Sigma) \Big|_{t=0} \right] (I - M) \right) \right] \\
& \stackrel{(ii)}{=} 2\mathbf{E}_{X_0} \left[\text{Tr} \left((I - M) G(X_0, B_j)^\top \Sigma^{-1} \frac{d}{dt} G(X_0, B_j + t \mathbf{E}_U [U_\Sigma^{-1} S_j U_\Sigma]) \Big|_{t=0} (I - M) \right) \right] \\
& = 2\mathbf{E}_{X_0} \left[\text{Tr} \left((I - M) G(X_0, B_j)^\top \Sigma^{-1} \frac{d}{dt} G(X_0, B_j + t s_j I) \Big|_{t=0} (I - M) \right) \right] \\
& = \left. \frac{d}{dt} f(A, B(t s_j I, j)) \right|_{t=0}
\end{aligned}$$

其中 $s_j := \frac{1}{d} \text{Tr}(\Sigma^{-1/2} S_j \Sigma^{1/2})$ 。在上面, (i) 使用 1。(25) 和 (26), 以及 $U_\Sigma^\top \Sigma^{-1} U_\Sigma = \Sigma^{-1}$ 的事实。(ii) 使用 $\frac{d}{dt} G(X_0, B_j + t C) \Big|_{t=0}$ 在 C 上是仿射的这一事实。要看到这一点, 可以验证从 (22) 出发, 使用简单的归纳法论证, $\frac{d}{dt} X_i(X_0, B_j + t C)$ 在 C 上是仿射的, 对于所有 i 。然后我们可以根据 G 的定义进行验证, 例如使用与 (26) 证明中类似的代数方法, $\frac{d}{dt} G(X_0, B_j + C)$ 在 $\frac{d}{dt} X_i(X_0, B_j + t C)$ 上是仿射的。因此 $\mathbf{E}_U [G(X_0, B_j + t U_\Sigma^{-1} S_j U_\Sigma)] = G(X_0, B_j + t \mathbf{E}_U [U_\Sigma^{-1} S_j U_\Sigma])$ 。

有了这个，我们完成了对 (18) 的证明。

Step 5: (17)的证明

我们现在将针对固定但任意的 j 证明 (17)，即存在某个 r_j 使得

$$\frac{d}{dt}f(A(t \cdot r_j \Sigma^{-1}, j), B) \leq \frac{d}{dt}f(A(tR_j, j), B).$$

证明与我们刚刚看到的(18)的证明非常相似，我们将基本上重复上面步骤 2-4 中的相同步骤。

让我们引入一个重新定义：令 $X_i(X, C)$ (分别 $Y_i(X, C)$) 表示从 (12) 开始的 X_i (分别 Y_i) 的值，带有 $X_0 = X$ ，以及 $A_j = C$ (以前是带有 $B_j = C$)。再次，令 $G(X, C) := X \prod_{i=0}^j (I + MX_i(X, C)^\top \bar{A}_i X_i(X, C))$ ，其中 $\bar{A}_j = A_j + tC$ ，以及 $\bar{A}_\ell = A_\ell$ 对所有 $\ell \in \{0 \dots k\} \setminus \{j\}$ 。

我们首先验证了

$$\begin{aligned} X_i(U_\Sigma X_0, B_j) &= U_\Sigma X_i(X_0, B_j) \\ G(U_\Sigma X_0, B_j) &= U_\Sigma G(X_0, B_j). \end{aligned} \quad (46)$$

证明与 (20) 和 (25) 的证明相同，因此我们省略它们。接下来，我们证明对于所有 i ，

$$U_\Sigma^{-1} \frac{d}{dt} X_i(U_\Sigma X_0, A_j + tR_j) \Big|_{t=0} = \frac{d}{dt} X_i(X_0, A_j + tU_\Sigma^\top R_j U_\Sigma) \Big|_{t=0}. \quad (47)$$

我们为 (28) 的右边建立动力学方程：

$$\begin{aligned} \frac{d}{dt} X_\ell(X_0, A_j + tC) &= 0 \\ \frac{d}{dt} X_{j+1}(X_0, A_j + tC) &= B_j X_j(X_0, A_j) M X_j(X_0, A_j)^\top C X_j(X_0, A_j) \\ \frac{d}{dt} X_{i+1}(X_0, A_j + tC) &= \frac{d}{dt} X_i(X_0, A_j + tC) \\ &\quad + B_i \left(\frac{d}{dt} X_i(X_0, A_j + tC) \right) M X_i(X_0, A_j)^\top A_i X_i(X_0, A_j) \\ &\quad + B_i X_i(X_0, A_j) M \left(\frac{d}{dt} X_i(X_0, A_j + tC) \right)^\top A_i X_i(X_0, A_j) \\ &\quad + B_i X_i(X_0, A_j) M X_i(X_0, A_j)^\top A_i \left(\frac{d}{dt} X_i(X_0, A_j + tC) \right) \end{aligned} \quad (48)$$

类似于 (23)，我们证明对于 $i \leq j$ ，

$$\begin{aligned} U_\Sigma^{-1} \frac{d}{dt} X_i(U_\Sigma X_0, A_j + tR_j) &= 0 = U_\Sigma^{-1} \frac{d}{dt} X_i(U_\Sigma X_0, A_j + tU_\Sigma^\top R_j U_\Sigma) \\ U_\Sigma^{-1} \frac{d}{dt} X_{j+1}(U_\Sigma X_0, A_j + tR_j) &= U_\Sigma^{-1} B_j U_\Sigma X_j(X_0, A_j) M X_j(U_\Sigma X_0, A_j)^\top A_j \\ &= \frac{d}{dt} X_{j+1}(U_\Sigma X_0, A_j + tU_\Sigma^\top R_j U_\Sigma X_j). \end{aligned}$$

最后，在归纳步骤中，我们遵循相同的步骤直至 (24) 以证明

$$\begin{aligned}
& U_{\Sigma}^{-1} \frac{d}{dt} X_{i+1}(U_{\Sigma} X_0, A_j + tR_j) \\
&= \frac{d}{dt} X_i \left(X_0, A_j + tU_{\Sigma}^{\top} R_j U_{\Sigma} \right) \\
&\quad + B_i \left(\frac{d}{dt} X_i \left(X_0, A_j + tU_{\Sigma}^{\top} R_j U_{\Sigma} \right) \right) M X_i(X_0, A_j)^{\top} A_i X_i(X_0, A_j) \\
&\quad + B_i X_i(X_0, A_j) M \left(\frac{d}{dt} X_i \left(X_0, A_j + tU_{\Sigma}^{\top} R_j U_{\Sigma} \right) \right)^{\top} A_i X_i(X_0, A_j) \\
&\quad + B_i X_i(X_0, A_j) M X_i(X_0, A_j)^{\top} A_i \left(\frac{d}{dt} X_i \left(X_0, A_j + tU_{\Sigma}^{\top} R_j U_{\Sigma} \right) \right) \tag{49}
\end{aligned}$$

通过验证当 $C = U_{\Sigma}^{-1} S U_{\Sigma}$ 时，(30) 确切地与 (29) 的第三个方程相符，归纳证明完成。这结束了 (28) 的证明。

接下来，我们研究 $G(U_{\Sigma} X_0, A_j + tR_j)$ 的时间导数，并证明

$$U_{\Sigma}^{-1} \frac{d}{dt} G(U_{\Sigma} X_0, A_j + tR_j) = \frac{d}{dt} G(X_0, A_j + tU_{\Sigma}^{\top} R_j U_{\Sigma}). \tag{50}$$

这个证明在几个地方与(26)的证明有显著不同，因此我们下面提供了完整的推导过程。通过链式法则，我们可以写成

$$U_{\Sigma}^{-1} \frac{d}{dt} G(U_{\Sigma} X_0, A_j + tR_j) = \spadesuit + \heartsuit$$

哪里

$$\spadesuit := U_{\Sigma}^{-1} \frac{d}{dt} \left(U_{\Sigma} X_0 \prod_{i=0}^k \left(I + M X_i(U_{\Sigma} X_0, A_j + tR_j)^{\top} A_i X_i(U_{\Sigma} X_0, A_j + tR_j) \right) \right)$$

和

$$\begin{aligned}
\heartsuit := & U_{\Sigma}^{-1} U_{\Sigma} X_0 \left(\prod_{i=0}^{j-1} \left(I + M X_i(U_{\Sigma} X_0, A_j)^{\top} A_i X_i(U_{\Sigma} X_0, A_j) \right) \right) \\
& \cdot M X_j(U_{\Sigma} X_0, A_j)^{\top} R_j X_j(U_{\Sigma} X_0, A_j) \\
& \cdot \left(\prod_{i=j+1}^k \left(I + M X_i(U_{\Sigma} X_0, A_j)^{\top} A_i X_i(U_{\Sigma} X_0, A_j) \right) \right).
\end{aligned}$$

我们将分别简化 $\spadesuit$ 和 $\heartsuit$ ，并在最后验证它们的和可以恢复 (31) 的右边。我们从 $\spadesuit$ 开始，这些步骤与 (26) 的证明几乎相同。

$$\begin{aligned}
& \spadesuit \\
&= U_{\Sigma}^{-1} \frac{d}{dt} \left(U_{\Sigma} X_0 \prod_{i=0}^k \left(I + M X_i(U_{\Sigma} X_0, A_j + tR_j)^{\top} A_i X_i(U_{\Sigma} X_0, A_j + tR_j) \right) \right)
\end{aligned}$$

$$\begin{aligned}
&= X_0 \sum_{i=0}^k \left(\prod_{\ell=0}^{i-1} \left(I + MX_\ell(U_\Sigma X_0, A_j)^\top A_\ell X_i(U_\Sigma X_0, A_\ell) \right) \right) \\
&\quad \cdot M \frac{d}{dt} \left(X_i(U_\Sigma X_0, A_j + tR_j)^\top A_i X_i(U_\Sigma X_0, A_j + tR_j) \right) \\
&\quad \cdot \left(\prod_{\ell=i+1}^k \left(I + MX_\ell(U_\Sigma X_0, A_j)^\top A_\ell X_i(U_\Sigma X_0, A_\ell) \right) \right) \\
&\stackrel{(i)}{=} X_0 \sum_{i=0}^k \left(\prod_{\ell=0}^{i-1} \left(I + MX_\ell(X_0, A_j)^\top A_\ell X_\ell(X_0, A_\ell) \right) \right) \\
&\quad \cdot M \left(\left(U_\Sigma^{-1} \frac{d}{dt} X_i(U_\Sigma X_0, A_j + tR_j) \right)^\top A_i X_i(X_0, A_j) + MX_i(X_0, A_j)^\top A_i \left(U_\Sigma^{-1} \frac{d}{dt} X_i(U_\Sigma X_0, A_j + tR_j) \right) \right) \\
&\quad \cdot \left(\prod_{\ell=i+1}^k \left(I + MX_\ell(X_0, A_j)^\top A_\ell X_\ell(X_0, A_\ell) \right) \right) \\
&\stackrel{(ii)}{=} X_0 \sum_{i=0}^k \left(\prod_{\ell=0}^{i-1} \left(I + MX_\ell(X_0, A_j)^\top A_\ell X_\ell(X_0, A_\ell) \right) \right) \\
&\quad \cdot M \left(\left(\frac{d}{dt} X_i(X_0, A_j + tU_\Sigma^\top R_j U_\Sigma) \right)^\top A_i X_i(X_0, A_j) + MX_i(X_0, A_j)^\top A_i \left(\frac{d}{dt} X_i(X_0, A_j + tU_\Sigma^\top R_j U_\Sigma) \right) \right) \\
&\quad \cdot \left(\prod_{\ell=i+1}^k \left(I + MX_\ell(X_0, A_j)^\top A_\ell X_\ell(X_0, A_\ell) \right) \right) \\
&= X_0 \sum_{i=0}^k \left(\prod_{\ell=0}^{i-1} \left(I + MX_\ell(X_0, A_j)^\top A_\ell X_\ell(X_0, A_\ell) \right) \right) \\
&\quad \cdot M \frac{d}{dt} \left(X_i(X_0, A_j + tU_\Sigma^\top R_j U_\Sigma)^\top A_i X_i(X_0, A_j + tU_\Sigma^\top R_j U_\Sigma) \right) \\
&\quad \cdot \left(\prod_{\ell=i+1}^k \left(I + MX_\ell(X_0, A_j)^\top A_\ell X_\ell(X_0, A_\ell) \right) \right) \tag{51}
\end{aligned}$$

在 (i) 上面, 我们有以下事实: 1. $X_i(U_\Sigma X_0, B_j) = U_\Sigma X_i(X_0, B_j)$ 来自 (27), 2. $A_i = a_i \Sigma^{-1}$, 使得 $U_\Sigma^\top A_i U_\Sigma = A_i$, 3. $U_\Sigma U_\Sigma^{-1} = U_\Sigma^{-1} U_\Sigma = I$ 。 (ii) 来自 (28)。

我们现在将简化 $\heartsuit$ 。

$$\begin{aligned}
&\heartsuit \\
&= U_\Sigma^{-1} U_\Sigma X_0 \left(\prod_{i=0}^{j-1} \left(I + MX_i(U_\Sigma X_0, A_j)^\top A_i X_i(U_\Sigma X_0, A_j) \right) \right) \\
&\quad \cdot MX_j(U_\Sigma X_0, A_j)^\top R_j X_j(U_\Sigma X_0, A_j) \\
&\quad \cdot \left(\prod_{i=j+1}^k \left(I + MX_i(U_\Sigma X_0, A_j)^\top A_i X_i(U_\Sigma X_0, A_j) \right) \right)
\end{aligned}$$

$$\begin{aligned}
& \stackrel{(i)}{=} X_0 \left(\prod_{i=0}^{j-1} \left(I + M X_i(X_0, A_j)^\top A_i X_i(X_0, A_j) \right) \right) M X_j(X_0, A_j)^\top U_\Sigma^\top R_j U_\Sigma X_j(X_0, A_j) \\
& \quad \cdot \left(\prod_{i=j+1}^k \left(I + M X_i(X_0, A_j)^\top A_i X_i(X_0, A_j) \right) \right), \tag{52}
\end{aligned}$$

其中 (i) 利用了 $X_i(U_\Sigma X_0, B_j) = U_\Sigma X_i(X_0, B_j)$ 来自 (27) 的事实以及 $A_i = a_i \Sigma^{-1}$ 的事实。

通过展开 $\frac{d}{dt} G(X_0, A_j + t U_\Sigma^\top R_j U_\Sigma)$ ，我们验证可知

$$\frac{d}{dt} G(X_0, A_j + t U_\Sigma^\top R_j U_\Sigma) = (32) + (33) = \spadesuit + \heartsuit = U_\Sigma^{-1} \frac{d}{dt} G(U_\Sigma X_0, A_j + t R_j),$$

这就完成了(31)的证明。

证明的其余部分与步骤 4 中在(19)所做的类似：

$$\begin{aligned}
& \left. \frac{d}{dt} f(A(t R_j, j), B) \right|_{t=0} \\
&= 2 \mathbf{E}_{X_0, U} \left[\text{Tr} \left((I - M) G(U_\Sigma X_0, A_j)^\top \Sigma^{-1} \left. \frac{d}{dt} G(U_\Sigma X_0, A_j + t R_j) \right|_{t=0} (I - M) \right) \right] \\
&\stackrel{(i)}{=} 2 \mathbf{E}_{X_0, U} \left[\text{Tr} \left((I - M) G(X_0, A_j)^\top \Sigma^{-1} \left. \frac{d}{dt} G(X_0, A_j + t U_\Sigma^\top R_j U_\Sigma) \right|_{t=0} (I - M) \right) \right] \\
&\stackrel{(ii)}{=} 2 \mathbf{E}_{X_0} \left[\text{Tr} \left((I - M) G(X_0, A_j)^\top \Sigma^{-1} \left. \frac{d}{dt} G(X_0, A_j + t \mathbf{E}_U [U_\Sigma^\top R_j U_\Sigma]) \right|_{t=0} (I - M) \right) \right] \\
&= 2 \mathbf{E}_{X_0} \left[\text{Tr} \left((I - M) G(X_0, A_j)^\top \Sigma^{-1} \left. \frac{d}{dt} G(X_0, A_j + t \cdot r_j \Sigma^{-1}) \right|_{t=0} (I - M) \right) \right] \\
&= \left. \frac{d}{dt} f(A(t \cdot r_j \Sigma^{-1}, j), B) \right|_{t=0},
\end{aligned}$$

其中 $r_j := \frac{1}{d} \text{Tr}(\Sigma^{1/2} R_j \Sigma^{1/2})$ 。在上面，(i) 使用 1。(27) 和 (31)，以及 $U_\Sigma^\top \Sigma^{-1} U_\Sigma = \Sigma^{-1}$ 的事实。(ii) 使用 $\left. \frac{d}{dt} G(X_0, A_j + t C) \right|_{t=0}$ 在 C 上是仿射的这一事实。要看到这一点，可以使用简单的归纳法论证，验证 $\left. \frac{d}{dt} X_i(X_0, A_j + t C) \right|_{t=0}$ 在 C 上是仿射的，对于所有 i 。然后可以从 G 的定义中验证，例如使用与 (31) 的证明类似的代数， $\left. \frac{d}{dt} G(X_0, A_j + C) \right|_{t=0}$ 在 $\left. \frac{d}{dt} X_i(X_0, A_j + t C) \right|_{t=0}$ 和 C 上是仿射的。因此 $\mathbf{E}_U [G(X_0, A_j + t U_\Sigma^\top R_j U_\Sigma)] = G(X_0, A_j + t \mathbf{E}_U [U_\Sigma^\top R_j U_\Sigma])$ 。

这就完成了 (17) 的证明，从而完成了整个定理的证明。

B.4 置换下的等价性

Lemma 8. 考虑与定理 4 相同的设置。令 $A = \{A_i\}_{i=0}^k$ ，其中 $A_i = a_i \Sigma^{-1}$ 。令 $f(A) := f \left(\left\{ Q_i = \begin{bmatrix} A_i & 0 \\ 0 & 0 \end{bmatrix}, P_i = \begin{bmatrix} 0_{d \times d} & 0 \\ 0 & 1 \end{bmatrix} \right\}_{i=0}^k \right)$ 。令 $i, j \in \{0 \dots k\}$ 为任意两个不同的索引，并令 $\tilde{A}_i = A_j$ ， $\tilde{A}_j = A_i$ ，并且令 $\tilde{A}_\ell = A_\ell$ 对所有 $\ell \in \{0 \dots k\} \setminus \{i, j\}$ 。那么 $f(A) = f(\tilde{A})$ 。

证明。按照在定理4证明中导致(4)的相同设置，我们验证上下文损失是

$$f(A) = \mathbf{E} \left[\text{Tr} \left((I - M) G(X_0, A)^\top \Sigma^{-1} G(X_0, A) (I - M) \right) \right]$$

其中 $G(X_0, A) := X_0 \prod_{\ell=0}^k (I + MX_0^\top A_\ell X_0)$ 。

考虑任何固定的索引 ℓ 。我们将证明

$$(I + MX_0^\top A_\ell X_0) (I + MX_0^\top A_{\ell+1} X_0) = (I + MX_0^\top A_{\ell+1} X_0) (I + MX_0^\top A_\ell X_0).$$

引理可以通过反复应用上述方法来证明，从而交换 A_i 和 A_j 的索引。

为了证明上述等式，

$$\begin{aligned} & (I + MX_0^\top A_\ell X_0) (I + MX_0^\top A_{\ell+1} X_0) \\ &= I + MX_0^\top A_\ell X_0 + MX_0^\top A_{\ell+1} X_0 + MX_0^\top A_\ell X_0 MX_0^\top A_{\ell+1} X_0 \\ &= I + MX_0^\top A_\ell X_0 + MX_0^\top A_{\ell+1} X_0 + MX_0^\top a_\ell \Sigma^{-1} X_0 MX_0^\top a_{\ell+1} \Sigma^{-1} X_0 \\ &= I + MX_0^\top A_\ell X_0 + MX_0^\top A_{\ell+1} X_0 + MX_0^\top a_{\ell+1} \Sigma^{-1} X_0 MX_0^\top a_\ell \Sigma^{-1} X_0 \\ &= (I + MX_0^\top A_{\ell+1} X_0) (I + MX_0^\top A_\ell X_0). \end{aligned}$$

这就完成了证明。注意我们关键地使用了 A_ℓ 和 $A_{\ell+1}$ 是相同矩阵，只是有缩放差异。 $\square$

C 辅助引理

C.1 重新制定上下文损失

在本节中，我们将开发一种上下文损失的重新表述，如 (3) 所定义的，在更方便的形式中（参见引理 9）。

本节中，我们假设 Transformer 参数 $\{P_i, Q_i\}_{i=0}^k$ 的形式如 (6) 中定义的那样，我们下面重新列出以便参考：

$$P_i = \begin{bmatrix} B_i & 0 \\ 0 & 1 \end{bmatrix}, \quad Q_i = \begin{bmatrix} A_i & 0 \\ 0 & 0 \end{bmatrix}.$$

回忆 (3) 中的更新动力学，我们将其重新列出如下：

$$Z_{i+1} = Z_i + \frac{1}{n} P Z_i M Z_i^\top Q Z_i, \quad (53)$$

其中 M 是由 $M := \begin{bmatrix} I_{n \times n} & 0 \\ 0 & 0 \end{bmatrix}$ 给出的掩码矩阵。设 $X_k \in \mathbb{R}^{d \times n+1}$ 表示 Z_k 的前 d 行，设 $Y_k \in \mathbb{R}^{1 \times n+1}$ 表示 Z_k 的第 $(d+1)^{th}$ 行（最后一行）。那么 (34) 中的动力学等价于

$$\begin{aligned} X_{i+1} &= X_i + \frac{1}{n} B_i X_i M X_i^\top A_i X_i \\ Y_{i+1} &= Y_i + \frac{1}{n} Y_i M X_i^\top A_i X_i. \end{aligned} \quad (54)$$

我们下面给出从 (3) 的上下文损失的一种等价形式：

Lemma 9. 设 p_x 和 p_w 表示在 $\mathbb{R}^d$ 上的分布。设 $x^{(1)} \dots x^{(n+1)} \stackrel{iid}{\sim} p_x$ 和 $w_\star \sim p_w$ 。设 $Z_0 \in \mathbb{R}^{d+1 \times n+1}$ 在 (3) 中被具体定义为

$$Z_0 = \begin{bmatrix} x^{(1)} & x^{(2)} & \dots & x^{(n)} & x^{(n+1)} \\ y^{(1)} & y^{(2)} & \dots & y^{(n)} & 0 \end{bmatrix} \in \mathbb{R}^{(d+1) \times (n+1)}.$$

设 Z_k 表示线性 *Transformer* 的 $(k-1)^{th}$ 层的输出 (如 (34) 中定义, 在 Z_0 处初始化)。设 $f(\{P_i, Q_i\}_{i=0}^k)$ 表示在上下文中的损失, 如 (3) 中定义, 即

$$f(\{P_i, Q_i\}_{i=0}^k) = \mathbf{E}_{(Z_0, w_\star)} \left[\left([Z_k]_{(d+1), (n+1)} + w_\star^\top x^{(n+1)} \right)^2 \right]. \quad (55)$$

设 $\bar{Z}_0$ 为

$$\bar{Z}_0 = \begin{bmatrix} x^{(1)} & x^{(2)} & \dots & x^{(n)} & x^{(n+1)} \\ y^{(1)} & y^{(2)} & \dots & y^{(n)} & y^{(n+1)} \end{bmatrix} \in \mathbb{R}^{(d+1) \times (n+1)},$$

其中 $y^{(n+1)} = \langle w_\star, x^{(n+1)} \rangle$ 。设 $\bar{Z}_k$ 表示线性 *Transformer* 的 $(k-1)^{th}$ 层的输出 (如 (34) 中定义, 初始化为 $\bar{Z}_0$)。假设 $\{P_i, Q_i\}_{i=0}^k$ 具有 (6) 中的形式。那么 (3) 中的损失具有等价形式

$$f(\{A_i, B_i\}_{i=0}^k) = f(\{P_i, Q_i\}_{i=0}^k) = \mathbf{E}_{(\bar{Z}_0, w_\star)} \left[\text{Tr} \left((I - M) \bar{Y}_k^\top \bar{Y}_k (I - M) \right) \right],$$

其中 $\bar{Y}_k \in \mathbb{R}^{1 \times n+1}$ 是 $(d+1)^{th}$ 行的 $\bar{Z}_k$ 。

在证明引理 9 之前, 我们首先建立一个中间结果 (如下引理 10)。为便于讨论, 我们定义函数 $F_X(\{A_i, B_i\}_{i=0}^k, X_0, Y_0)$ 和 $F_Y(\{A_i, B_i\}_{i=0}^k, X_0, Y_0)$ 为经过 k 个 *Transformer* 层后的输出, 即

$$\begin{aligned} F_X(\{A_i, B_i\}_{i=0}^k, X_0, Y_0) &= X_{k+1} \\ F_Y(\{A_i, B_i\}_{i=0}^k, X_0, Y_0) &= Y_{k+1}, \end{aligned}$$

如在 (35) 中定义的, 给定初始化 X_0, Y_0 和参数矩阵 $\{A_i, B_i\}_{i=0}^k$ 。

我们现在证明一个有用的引理, 说明 $[Y_0]_{n+1} = y^{(n+1)}$ 以非常简单的方式影响 X_i, Y_i :

Lemma 10. 设 X_i, Y_i 遵循 (35) 中的动力学。然后

1. $[X_i]$ 与 $[Y_0]_{n+1}$ 无关。
2. 对于 $j \neq n+1$, $[Y_i]_j$ 不依赖于 $[Y_0]_{n+1}$ 。
3. $[Y_i]_{n+1}$ 与 $[Y_0]_{n+1}$ 有加性关系。

换句话说, 对于 $C := [0, 0, 0, \dots, 0, c] \in \mathbb{R}^{d+1 \times 1}$,

$$\begin{aligned} 1 : F_X(\{A_i, B_i\}_{i=0}^k, X_0, Y_0 + C) &= F_X(\{A_i, B_i\}_{i=0}^k, X_0, Y_0) \\ 2 + 3 : F_Y(\{A_i, B_i\}_{i=0}^k, X_0, Y_0 + C) &= F_Y(\{A_i, B_i\}_{i=0}^k, X_0, Y_0) + C \end{aligned}$$

Proof of Lemma 10. 第一个和第二个项直接来自于观察到在 X_i 和 Y_i 在 (35) 中的动力学不涉及 $[Y_i]_{n+1}$ ，这是由于 M 的影响。

第三个条目再次利用了 $Y_{i+1} - Y_i$ 与 $[Y_i]_{n+1}$ 无关的事实。 $\square$

我们现在已经准备好证明引理 9

Proof of Lemma 9. 设 Z_0 , Z_k , $\bar{Z}_0$, $\bar{Z}_k$ 如引理声明中所定义。设 $\bar{X}_k$ 和 $\bar{Y}_k$ 分别表示 $\bar{Z}_k$ 的前 d 行和最后一行。那么根据引理 10, $\bar{X}_k = X_k$ 和 $\bar{Y}_k = Y_k + \begin{bmatrix} 0 & 0 & \cdots & 0 & \langle w_\star, x^{(n+1)} \rangle \end{bmatrix}$ 。因此, $[Z_k]_{(d+1),(n+1)} + w_\star^\top x^{(n+1)} = [\bar{Z}_k]_{(d+1),(n+1)}$, 所以 (36) 等价于

$$\begin{aligned} & \mathbf{E}_{(\bar{Z}_0, w_\star)} \left[([\bar{Z}_k]_{(d+1),(n+1)})^2 \right] \\ &= \mathbf{E}_{(\bar{Z}_0, w_\star)} \left[([\bar{Y}_k]_{(n+1)})^2 \right] \\ &= \mathbf{E}_{(\bar{Z}_0, w_\star)} \left[\left\| (I - M) \bar{Y}_k^\top \right\|^2 \right] \\ &= \mathbf{E}_{(\bar{Z}_0, w_\star)} \left[\text{Tr} \left((I - M) \bar{Y}_k^\top \bar{Y}_k (I - M) \right) \right]. \end{aligned}$$

这证明了该命题。 $\square$

C.2 Lemma 2 的证明（与预条件梯度下降的等价性）

Proof of Lemma 2. 考虑固定的样本 $x^{(1)} \dots x^{(n)}$, 以及固定的 $w_\star$ 。令 $P = \{P_i\}_{i=0}^k, Q = \{Q_i\}_{i=0}^k$ 表示固定的权重。令 Z_i 在 (3) 中的动力学下演化, 如下所示以便参考

$$Z_{\ell+1} = Z_\ell + \frac{1}{n} \text{Attn}_{P_\ell, Q_\ell}(Z_\ell).$$

设 Y_ℓ 表示 $(d+1)^{\text{th}}$ 的第 Z_ℓ 行。我们验证在 (5) 下, 更新 $y_\ell^{(n+1)}$ 的公式为

$$Y_{\ell+1} = Y_\ell + \frac{1}{n} Y_\ell M X_0^\top A_\ell X_0, \quad (56)$$

其中 M 是由 $\begin{bmatrix} I & 0 \\ 0 & 0 \end{bmatrix}$ 给出的掩码。

我们还让 $y_\ell^{(i)} := [Y_\ell]_i$ 。让 $g(x, y, k) : \mathbb{R}^d \times \mathbb{R} \times \mathbb{Z} \rightarrow \mathbb{R}$ 是如下定义的函数: 让 $x^{(n+1)} = x$ 并且让 $y_0^{(n+1)} = y$, 然后 $g(x, y, k) := y_k^{(n+1)}$ 。注意 $y_k^{(n+1)} = [Y_k]_{n+1}$, 并且特别地 $y_0^{(n+1)} = y^{(n+1)}$ 。我们可以验证以下事实

1. $g(x, y, \ell) = g(x, 0, \ell) + y$ 。这是因为 (37) 表明 $i \in \{1 \dots n\}$,

$$y_{\ell+1}^{(i)} = y_\ell^{(i)} + \frac{1}{n} \sum_{j=1}^n x^{(i)\top} A_\ell x^{(j)} y_\ell^{(j)}. \quad (57)$$

换句话说, $y_\ell^{(i)}$ 与 $y_t^{(n+1)}$ 无关, 对于任何 t 都成立。接下来, 对于 $y_\ell^{(n+1)}$ 本身,

$$y_{\ell+1}^{(n+1)} = y_\ell^{(n+1)} + \frac{1}{n} \sum_{j=1}^n x^{(n+1)\top} A_\ell x^{(j)} y_\ell^{(j)}. \quad (58)$$

换句话说, $y_{\ell+1}^{(n+1)} - y_\ell^{(n+1)}$ 再次不依赖于 $y_t^{(n+1)}$ 对于任何 t 。一个简单的归纳法证明表明, $g(x, y, \ell + 1) - g(x, 0, \ell + 1) = g(x, y, \ell) - g(x, 0, \ell) = \dots = g(x, y, 0) - g(x, 0, 0) = y$ 对所有 ℓ 和所有 x, y 都成立。

2. $g(x, 0, \ell)$ 是 x 的线性函数。为了验证这一点, 注意从 (38) 可知, 当 $j \neq n+1$ 时, $y_\ell^{(j)}$ 不依赖于 $x_t^{(n+1)}$ 对所有 t, j, ℓ 来说。接下来, 考虑当 $j = n+1$ 时: $y_{\ell+1}^{(n+1)}$ 在 (39) 中是 $y_\ell^{(n+1)}$ 与一个线性依赖于 $x^{(n+1)}$ 的项的和 (因为 A_ℓ 和 $y^{(\ell)}$ 不依赖于 $x^{(n+1)}$ 和 $y_\ell^{(n+1)}$)。由于 $y_0^{(n+1)} = 0$ 是 $x = x^{(n+1)}$ 的线性函数, 因此通过归纳法可得出所需的结论。

考虑到这两个事实, 我们验证了对于每个 ℓ , 以及任何 x, y , 存在一个 $\theta_\ell \in \mathbb{R}^d$, 该 $\theta_\ell \in \mathbb{R}^d$ 不依赖于 x, y , 使得

$$g(x, y, \ell) = g(x, 0, \ell) + y = \langle \theta_\ell, x \rangle + y. \quad (59)$$

根据定义可知 $g(x, y, 0) = y$, 因此 $\langle \theta_0, x \rangle = g(x, y, 0) - y = 0$, 因此 $\theta_0 = 0$ 。我们现在将注意力转向第三个关键事实: 对于所有 $i \in \{1 \dots n+1\}$,

$$y_\ell^{(i)} = g(x^{(i)}, y^{(i)}, \ell) = \langle \theta_\ell, x^{(i)} \rangle + y^{(i)} \quad (60)$$

我们刚刚证明了当 (41) 成立时 $i = n+1$ 。现在我们将证明它对任意的 $i \in \{1 \dots n\}$ 成立。由于 (40) 对任何 x, y 都成立, 我们可以选择 $x := x^{(i)}$ 和 $y := \langle y^{(i)}, w_\star \rangle$ 。根据 (38), recalled that,

$$y_{\ell+1}^{(i)} = y_\ell^{(i)} + \frac{1}{n} \sum_{j=1}^n x^{(n+1)\top} A_\ell x^{(j)} y_\ell^{(j)} \quad (61)$$

在 $y_0^{(i)} = \langle w_\star, x^{(i)} \rangle$ 处初始化。另一方面, 通过我们对 x 的选择, $y_\ell^{(n+1)}$ 在 (39) 中带有 $x^{(n+1)} = x^{(i)}$ 的动力学与 $y_\ell^{(i)}$ 在 (42) 中的动力学是确切相同的。此外, $y_0^{(n+1)} = y = y_0^{(i)}$ 在这种选择下也是如此。因此, 必须有 $y_\ell^{(n+1)} = y_\ell^{(i)}$ 对所有 ℓ 成立, 这证明了 (41)。

设 $\bar{X} \in \mathbb{R}^{d \times n}$ 为列向量为 $x^{(1)} \dots x^{(n)}$ 的矩阵, 去掉 $x^{(n+1)}$ 。设 $\bar{Y}_\ell \in \mathbb{R}^{1 \times n}$ 表示 $[y_\ell^{(1)} \dots y_\ell^{(n)}]$ 的向量。

我们将 (39) 重写为等价形式,

$$\begin{aligned} y_{\ell+1}^{(n+1)} &= y_\ell^{(n+1)} + \frac{1}{n} \langle A_\ell \bar{X} \bar{Y}_\ell^\top, x^{(n+1)} \rangle \\ &= y_\ell^{(n+1)} + \frac{1}{n} \langle A_\ell \bar{X} (\bar{X}^\top \theta_\ell + \bar{Y}_0^\top), x^{(n+1)} \rangle \\ &= y_\ell^{(n+1)} + \frac{1}{n} \langle A_\ell \bar{X} (\bar{X}^\top (\theta_\ell + w_\star)), x^{(n+1)} \rangle \end{aligned}$$

其中第二个等号来自于 (41), 第三个等号来自于 $y^{(i)} = \langle x^{(i)}, w_\star \rangle$ 的事实。代入 $y_\ell^{(n+1)} = y^{(n+1)} + \langle \theta_\ell, x^{(n+1)} \rangle$ 得到

$$\langle \theta_{\ell+1}, x^{(n+1)} \rangle = \langle \theta_\ell, x^{(n+1)} \rangle + \frac{1}{n} \langle A_\ell \bar{X} (\bar{X}^\top (\theta_\ell + w_\star)), x^{(n+1)} \rangle$$

由于 $x^{(n+1)}$ 的选择是任意的, 我们得到更一般的更新公式

$$\theta_{\ell+1} = \theta_{\ell} + \frac{1}{n} A_{\ell} \bar{X} \bar{X}^{\top} (\theta_{\ell} + w_{\star}). \quad (63)$$

设 $R_{w_{\star}}(w) = \frac{1}{2n} \sum_{i=1}^n (w^{\top} x_i - w_{\star}^{\top} x_i)^2 = \frac{1}{2n} (-w + w_{\star})^{\top} \bar{X} \bar{X}^{\top} (-w + w_{\star})$ 如引理声明中所定义, 令 $w^{\text{gd}} := -\theta_k$ 。则 (45) 等价于

$$w_{\ell+1}^{\text{gd}} = w_{\ell}^{\text{gd}} + A_{\ell} \nabla R_{w_{\star}}(w_{\ell}^{\text{gd}}). \quad (64)$$

一起, (45) 和 (41) (与 $i = n + 1$ 和 $y^{(n+1)} = 0$ 一起) 确切地给出了我们期望的结论。 $\square$